

Estatística para Administração

Prof. Ismael Bastos



Introdução à Estatística e Informações da Disciplina

O que é Estatística

Entendemos a Estatística como um conjunto de técnicas que permite, de forma sistemática, organizar, descrever, analisar e interpretar dados oriundos de estudos ou experimentos, realizados em qualquer área do conhecimento.

Áreas da Estatística

Podemos dividir a Estatística em três áreas:

- Estatística Descritiva
- Probabilidade
- Inferência Estatística

Áreas da Estatística

- **Estatística Descritiva** (*Conheça seus dados*) : Etapa inicial em qualquer análise de dados. É um conjunto de métodos estatísticos que tem por objetivo a organização, descrição e o resumo de dados.


Áreas da Estatística

- **Estatística Descritiva** (*Conheça seus dados*) : Etapa inicial em qualquer análise de dados. É um conjunto de métodos estatísticos que tem por objetivo a organização, descrição e o resumo de dados.
- **Probabilidade** (*Qual a incerteza associada aos dados?*) : Auxilia na modelagem de fenômenos aleatórios, ou seja, aqueles em que há incerteza.

Áreas da Estatística

- **Estatística Descritiva** (*Conheça seus dados*) : Etapa inicial em qualquer análise de dados. É um conjunto de métodos estatísticos que tem por objetivo a organização, descrição e o resumo de dados.
- **Probabilidade** (*Qual a incerteza associada aos dados?*) : Auxilia na modelagem de fenômenos aleatórios, ou seja, aqueles em que há incerteza.
- **Inferência Estatística** (*Quais conclusões podemos tirar a partir destes dados?*): É um método estatístico que possibilita tirar conclusões sobre uma população a partir de informações contidas na amostra.


População x Amostra



População x Amostra

Por que precisamos selecionar uma amostra?

Áreas da Estatística



Informações da Disciplina

- Trabalho 1 valendo 10 pontos
- Prova 1 valendo 10 pontos
- Prova 2 valendo 10 pontos

$$\text{Nota Final} = 0,4 \cdot T_1 + 0,3 \cdot P_1 + 0,3 \cdot P_2$$

Funcionamento da disciplina

- Aulas expositivas com conteúdo em slide.
- Aulas práticas envolvendo aplicações.
- Resolução de exemplos e exercícios no quadro *.
- Uso da linguagem de programação R.
- Disponibilização de informações da disciplina através do site da disciplina e do SIGA.
- Listas de exercício
- Alguns códigos estarão presentes nos slides, mas alguns outros serão disponibilizados separadamente.

*: A resolução de exemplos e exercícios não será disponibilizada no site.

Linguagem de programação R

- Por que usar a linguagem R para estatística?
- Instalação do R e R Studio.
- Posit Cloud.

Perguntas iniciais

- Como garantir que uma amostra representa bem a população?
 - Qual metodologia devo utilizar para selecionar minha amostra?
Exemplo: Quero conduzir uma pesquisa eleitoral na cidade de São Paulo, como devo escolher as pessoas que vou entrevistar?

Perguntas iniciais

- Como garantir que uma amostra representa bem a população?
 - Qual metodologia devo utilizar para selecionar minha amostra?
Exemplo: Quero conduzir uma pesquisa eleitoral na cidade de São Paulo, como devo escolher as pessoas que vou entrevistar?
 - Qual tamanho de amostra selecionar?
Exemplo: Sei que o tamanho da população de São Paulo é de aproximadamente 11,45 milhões de habitantes, quantas pessoas devo escolher?

Amostragem

Amostragem aleatória simples

Amostragem aleatória simples: Consideremos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória simples é feita da seguinte forma:

- 1) Numeramos os itens da população com número de 1 até N .

Amostragem aleatória simples

Amostragem aleatória simples: Consideremos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória simples é feita da seguinte forma:

- 1) Numeramos os itens da população com número de 1 até N .
- 2) Escrevemos cada um desses números em uma pedaço de papel.

Amostragem aleatória simples

Amostragem aleatória simples: Consideremos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória simples é feita da seguinte forma:

- 1) Numeramos os itens da população com número de 1 até N .
- 2) Escrevemos cada um desses números em uma pedaço de papel.
- 3) Colocamos esses papeis em uma urna bem misturados.

Amostragem aleatória simples

Amostragem aleatória simples: Consideremos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória simples é feita da seguinte forma:

- 1) Numeramos os itens da população com número de 1 até N .
- 2) Escrevemos cada um desses números em uma pedaço de papel.
- 3) Colocamos esses papeis em uma urna bem misturados.
- 4) Tiramos os n papeis correspondentes à amostra.

Amostragem aleatória simples

Amostragem aleatória simples: Consideremos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória simples é feita da seguinte forma:

- 1) Numeramos os itens da população com número de 1 até N .
- 2) Escrevemos cada um desses números em uma pedaço de papel.
- 3) Colocamos esses papeis em uma urna bem misturados.
- 4) Tiramos os n papeis correspondentes à amostra.

Pergunta: Essa retirada é com ou sem reposição?

Amostragem aleatória simples - Exemplo

Exemplo 1: O estudo **O perfil socioeconômico e a percepção ambiental dos pescadores da Lagoa de Apodi, Rio Grande do Norte, Brasil** propõe uma amostragem aleatória simples como metodologia de amostragem.

Amostragem aleatória simples - Exemplo no R

Nesse exemplo do R estamos assumindo que temos uma população de 10 indivíduos cujos nomes estão armazenadas no vetor *populacao* e desejamos obter uma amostra de tamanho 3 utilizando a amostragem aleatória simples.

Amostragem aleatória simples no R

```
n = 3  
populacao = c("Tom", "Lia", "Ema", "Max", "Ana",  
  ↪ "Lua", "Mia", "Isa", "Ilo", "Gal")  
amostra = sample(populacao, n)
```

Amostragem aleatória simples - Exemplo no R

Nesse exemplo do R estamos assumindo que temos uma população de 10 indivíduos cujos nomes estão armazenadas no vetor *populacao* e desejamos obter uma amostra de tamanho 3 utilizando a amostragem aleatória simples.

Amostragem aleatória simples no R

```
n = 3  
populacao = c("Tom", "Lia", "Ema", "Max", "Ana",  
  ↪ "Lua", "Mia", "Isa", "Ilo", "Gal")  
amostra = sample(populacao, n)
```

A função *sample* gera uma amostra aleatória simples de tamanho *n*, que nesse caso é 3.

Amostragem aleatória simples - Exemplo no R

Nesse exemplo do R estamos assumindo que temos uma população de 10 indivíduos cujos nomes estão armazenadas no vetor *populacao* e desejamos obter uma amostra de tamanho 3 utilizando a amostragem aleatória simples.

Amostragem aleatória simples no R

```
n = 3  
populacao = c("Tom", "Lia", "Ema", "Max", "Ana",  
  ↪ "Lua", "Mia", "Isa", "Ilo", "Gal")  
amostra = sample(populacao, n)
```

A função *sample* gera uma amostra aleatória simples de tamanho *n*, que nesse caso é 3.

Observação: A função *sample* por padrão gera uma amostra selecionada sem reposição, para gerar uma amostra com reposição, basta adicionar o argumento *replace = TRUE*.

Amostragem aleatória estratificada

Amostragem aleatória estratificada: Consideremos que temos uma população (**heterogênea**) de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória estratificada é feita da seguinte forma:

- 1) Dividimos a população em estratos (com base em Idade, Renda, Sexo, Escolaridade ou outra variável).

Amostragem aleatória estratificada

Amostragem aleatória estratificada: Consideremos que temos uma população (**heterogênea**) de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória estratificada é feita da seguinte forma:

- 1) Dividimos a população em estratos (com base em Idade, Renda, Sexo, Escolaridade ou outra variável).
- 2) Determinamos o tamanho da amostra que iremos retirar de cada estrato, podendo ser feito de duas principais formas:

Amostragem aleatória estratificada

Amostragem aleatória estratificada: Consideremos que temos uma população (**heterogênea**) de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória estratificada é feita da seguinte forma:

- 1) Dividimos a população em estratos (com base em Idade, Renda, Sexo, Escolaridade ou outra variável).
- 2) Determinamos o tamanho da amostra que iremos retirar de cada estrato, podendo ser feito de duas principais formas:
 - **Proporcional:** A quantidade de indivíduos amostrados em cada estrato é proporcional ao tamanho do estrato.
 - **Igualitária:** Selecionamos o mesmo número de indivíduos em cada estrato, não levando em conta o tamanho.

Amostragem aleatória estratificada

Amostragem aleatória estratificada: Consideremos que temos uma população (**heterogênea**) de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória estratificada é feita da seguinte forma:

- 1) Dividimos a população em estratos (com base em Idade, Renda, Sexo, Escolaridade ou outra variável).
- 2) Determinamos o tamanho da amostra que iremos retirar de cada estrato, podendo ser feito de duas principais formas:
 - **Proporcional:** A quantidade de indivíduos amostrados em cada estrato é proporcional ao tamanho do estrato.
 - **Igualitária:** Selecionamos o mesmo número de indivíduos em cada estrato, não levando em conta o tamanho.
- 3) Realizamos a amostragem aleatória simples em cada estrato.

Amostragem aleatória estratificada - Exemplo

Exemplo 2: O estudo **Hipertensão Arterial e Diabetes Mellitus** entre trabalhadores da saúde: **associação com hábitos de vida e estressores ocupacionais** propõe uma amostragem aleatória estratificada como metodologia de amostragem.

Amostragem aleatória estratificada - Exemplo no R

Amostragem aleatória estratificada (Proporcional) no R

```
n = 3  
populacao = c("Tom", "Lia", "Ema", "Max", "Ana",  
  ↪ "Lua", "Mia", "Isa", "Ilo", "Gal")  
populacao_M = c("Tom", "Max", "Ilo")  
populacao_F = c("Lia", "Ema", "Ana", "Lua", "Mia",  
  ↪ "Isa", "Gal")  
amostra_1 = sample(populacao_M, round(0.3 * n))  
amostra_2 = sample(populacao_F, round(0.7 * n))  
amostra = c(amostra_1, amostra_2)
```

Amostragem aleatória estratificada

Amostragem aleatória estratificada em duas etapas:

Consideremos que temos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória estratificada em duas etapas é feita da seguinte forma:

- 1) Dividimos a população em estratos (com base em Idade, Renda, Sexo, Escolaridade ou outra variável).

Amostragem aleatória estratificada

Amostragem aleatória estratificada em duas etapas:

Consideremos que temos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória estratificada em duas etapas é feita da seguinte forma:

- 1) Dividimos a população em estratos (com base em Idade, Renda, Sexo, Escolaridade ou outra variável).
- 2) Selecionamos aleatoriamente subconjuntos desses estratos.

Amostragem aleatória estratificada

Amostragem aleatória estratificada em duas etapas:

Consideremos que temos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória estratificada em duas etapas é feita da seguinte forma:

- 1) Dividimos a população em estratos (com base em Idade, Renda, Sexo, Escolaridade ou outra variável).
- 2) Selecionamos aleatoriamente subconjuntos desses estratos.
- 3) Realizamos amostragem aleatória simples dentro de cada grupo.

Amostragem aleatória estratificada

Amostragem aleatória estratificada em duas etapas:

Consideremos que temos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória estratificada em duas etapas é feita da seguinte forma:

- 1) Dividimos a população em estratos (com base em Idade, Renda, Sexo, Escolaridade ou outra variável).
- 2) Selecionamos aleatoriamente subconjuntos desses estratos.
- 3) Realizamos amostragem aleatória simples dentro de cada grupo.

Atenção: O número de etapas não está necessariamente relacionado ao número de variáveis.

Amostragem aleatória por conglomerados

Amostragem aleatória por conglomerados: Consideremos que temos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória por conglomerados é feita da seguinte forma:

- 1) Dividimos a população em conglomerados (como, por exemplo, escolas, unidades de saúde, bairros, etc.).

Amostragem aleatória por conglomerados

Amostragem aleatória por conglomerados: Consideremos que temos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória por conglomerados é feita da seguinte forma:

- 1) Dividimos a população em conglomerados (como, por exemplo, escolas, unidades de saúde, bairros, etc.).
- 2) Selecionamos aleatoriamente um subconjunto desses conglomerados.

Amostragem aleatória por conglomerados

Amostragem aleatória por conglomerados: Consideremos que temos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória por conglomerados é feita da seguinte forma:

- 1) Dividimos a população em conglomerados (como, por exemplo, escolas, unidades de saúde, bairros, etc.).
- 2) Selecionamos aleatoriamente um subconjunto desses conglomerados.
- 3) Todos os indivíduos dentro dos conglomerados selecionados são estudados

Amostragem aleatória por conglomerados X Amostragem aleatória estratificada

Importante: Não confundir amostragem aleatória por conglomerados com amostragem aleatória estratificada.

Amostragem aleatória por conglomerados	Amostragem aleatória estratificada
Grupos (Conglomerados) heterogêneos em seu interior	Grupos (Estratos) homogêneos em seu interior
Grupos (Conglomerados) homogêneos entre si	Grupos (Estratos) heterogêneos entre si

Amostragem aleatória sistemática

Amostragem aleatória sistemática: Consideremos que temos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória sistemática é feita da seguinte forma:

- 1) Determinamos o intervalo de amostragem $k = \frac{N}{n}$.

Amostragem aleatória sistemática

Amostragem aleatória sistemática: Consideremos que temos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória sistemática é feita da seguinte forma:

- 1) Determinamos o intervalo de amostragem $k = \frac{N}{n}$.
- 2) Selecionamos aleatoriamente um número entre 1 e k como ponto de partida.

Amostragem aleatória sistemática

Amostragem aleatória sistemática: Consideremos que temos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória sistemática é feita da seguinte forma:

- 1) Determinamos o intervalo de amostragem $k = \frac{N}{n}$.
- 2) Selecionamos aleatoriamente um número entre 1 e k como ponto de partida.
- 3) Selecionamos os elementos da amostra a partir do ponto de partida, seguindo o intervalo k .

Amostragem aleatória sistemática

Amostragem aleatória sistemática: Consideremos que temos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória sistemática é feita da seguinte forma:

- 1) Determinamos o intervalo de amostragem $k = \frac{N}{n}$.
- 2) Selecionamos aleatoriamente um número entre 1 e k como ponto de partida.
- 3) Selecionamos os elementos da amostra a partir do ponto de partida, seguindo o intervalo k .

Perguntas:

- 1) No passo 1, precisamos de fato definir k dessa forma? Em qual situação que poderíamos defini-lo de outra forma?

Amostragem aleatória sistemática

Amostragem aleatória sistemática: Consideremos que temos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória sistemática é feita da seguinte forma:

- 1) Determinamos o intervalo de amostragem $k = \frac{N}{n}$.
- 2) Selecionamos aleatoriamente um número entre 1 e k como ponto de partida.
- 3) Selecionamos os elementos da amostra a partir do ponto de partida, seguindo o intervalo k .

Perguntas:

- 1) No passo 1, precisamos de fato definir k dessa forma? Em qual situação que poderíamos defini-lo de outra forma?
- 2) Qual o principal possível problema dessa abordagem?

Amostragem aleatória sistemática

Amostragem aleatória sistemática: Consideremos que temos uma população de tamanho N e desejamos uma amostra de tamanho n . A amostragem aleatória sistemática é feita da seguinte forma:

- 1) Determinamos o intervalo de amostragem $k = \frac{N}{n}$.
- 2) Selecionamos aleatoriamente um número entre 1 e k como ponto de partida.
- 3) Selecionamos os elementos da amostra a partir do ponto de partida, seguindo o intervalo k .

Perguntas:

- 1) No passo 1, precisamos de fato definir k dessa forma? Em qual situação que poderíamos defini-lo de outra forma?
- 2) Qual o principal possível problema dessa abordagem?

Amostragem aleatória por conglomerados e sistemática - Exemplo

Exemplo 3: O estudo *Associação da depressão com as características sociodemográficas, qualidade do sono e hábitos de vida em idosos do Nordeste brasileiro: estudo seccional de base populacional*. propõe uma amostragem aleatória por conglomerados seguido pela amostragem aleatória sistemática como metodologia de amostragem.

Outros tipos de amostragem

Considere, agora, que um aluno esteja interessado em avaliar a opinião dos alunos da UFRJ sobre o serviço de transporte entre os diversos campi, oferecido pela administração da universidade. Como ele não tem **condições** nem **tempo** de selecionar uma amostra de todos os alunos a UFRJ, decide entrevistar seus colegas de turma.

Outros tipos de amostragem

Considere, agora, que um aluno esteja interessado em avaliar a opinião dos alunos da UFRJ sobre o serviço de transporte entre os diversos campi, oferecido pela administração da universidade. Como ele não tem **condições** nem **tempo** de selecionar uma amostra de todos os alunos a UFRJ, decide entrevistar seus colegas de turma.

- A decisão desse aluno é razoável? Ou seja, essa amostra é representativa?
- Qual a diferença desse método para os que estudamos anteriormente?

Outros tipos de amostragem

Considere, agora, que um aluno esteja interessado em avaliar a opinião dos alunos da UFRJ sobre o serviço de transporte entre os diversos campi, oferecido pela administração da universidade. Como ele não tem **condições** nem **tempo** de selecionar uma amostra de todos os alunos a UFRJ, decide entrevistar seus colegas de turma.


- A decisão desse aluno é razoável? Ou seja, essa amostra é representativa?
- Qual a diferença desse método para os que estudamos anteriormente?

Esse tipo de amostragem é chamado de **amostragem por conveniência** e é um tipo de amostragem não-probabilística.

Outros tipos de amostragem

Os métodos de amostragem não-probabilísticos são ruins e não devem ser utilizados???

O problema do viés - Experimento de aprisionamento de Stanford (1971)



O problema do viés - Experimento de aprisionamento de Stanford (1971)

- Participantes de uma comunidade local foram convidados através de um anúncio de jornal que recrutava estudantes do sexo masculino para participar de um "**estudo psicológico da vida em uma prisão**".

O problema do viés - Experimento de aprisionamento de Stanford (1971)

- Participantes de uma comunidade local foram convidados através de um anúncio de jornal que recrutava estudantes do sexo masculino para participar de um "**estudo psicológico da vida em uma prisão**".
- Caso o estudante fosse aprovado, receberia \$15 por dia (equivalente a aproximadamente \$120 atualmente).

O problema do viés - Experimento de aprisionamento de Stanford (1971)


- Participantes de uma comunidade local foram convidados através de um anúncio de jornal que recrutava estudantes do sexo masculino para participar de um "**estudo psicológico da vida em uma prisão**".
- Caso o estudante fosse aprovado, receberia \$15 por dia (equivalente a aproximadamente \$120 atualmente).
- Os participantes foram submetidos a testes psicológicos e alocados aleatoriamente na posição de prisioneiro ou carcereiro.
- **Conclusão do Experimento:** Pessoas "boas" podem ter um "mal" comportamento quando colocadas em posições de poder ou sob condições de estresse.

Análise Exploratória de Dados

Tipos de variáveis

- **Variável:** Característica analisada (Nome da coluna)
 - **Quantitativa:** Assume valores numéricos
 - Discreta: Assume valores discretos, valores inteiros.
 - Contínua: Assume valores no intervalo dos números reais.
 - **Qualitativa:** Assume valores que representam atributos e/ou qualidades
 - **Ordinal:** Valores assumem ordem, indicando intensidade crescentes de realização
 - **Nominal:** Valores não assumem ordem

Tipos de variáveis



Tipos de variáveis

Exemplo inicial

Est. Civil	Instrução	Filhos	Salário	Idade
Solteiro	Fundamental	0	4,00	26
Casado	Médio	1	4,56	32
Casado	Superior	3	6,20	34
Solteiro	Médio	2	5,23	21
Casado	Superior	2	3,23	24
Solteiro	Médio	1	7,90	56
Casado	Fundamental	4	6,45	67
Casado	Fundamental	0	4,56	34
Solteiro	Médio	1	6,78	56
Solteiro	Superior	0	3,56	34

Tipos de variáveis

Atenção: Ao analisar as variáveis estamos olhando para a informação trazida e não para o valor em si.

Tipos de variáveis

Atenção: Ao analisar as variáveis estamos olhando para a informação trazida e não para o valor em si.

Est. Civil	Instrução	Filhos	Salário	Idade
1	1	0	4,00	26
2	2	1	4,56	32
2	3	3	6,20	34
1	2	2	5,23	21
2	3	2	3,23	24
1	2	1	7,90	56
2	1	4	6,45	67
2	1	0	4,56	34
1	2	1	6,78	56
1	3	0	3,56	34

Tipos de variáveis

Atenção: Ao analisar as variáveis estamos olhando para a informação trazida e não para o valor em si.

Est. Civil	Instrução	Filhos	Salário	Idade
1	1	0	4,00	26
2	2	1	4,56	32
2	3	3	6,20	34
1	2	2	5,23	21
2	3	2	3,23	24
1	2	1	7,90	56
2	1	4	6,45	67
2	1	0	4,56	34
1	2	1	6,78	56
1	3	0	3,56	34

Tipos de variáveis

Vamos para um exemplo real. Abrir base de dados do curso.

Tabela de frequência

Uma tabela de frequência relaciona categorias ou classes de valores juntamente com as frequências do número de valores que se enquadram em cada categoria ou classe.

Denotaremos por:

- n_i : Frequência absoluta
- f_i : Frequência relativa

onde, $f_i = \frac{n_i}{n}$

Tabela de frequência

Exemplo 4: Construa a tabela de frequência para a variável formação utilizando os dados da tabela abaixo

idade	experiência(anos)	sexo	cidade	formação	salário (R\$)
20	2	1	Rio de Janeiro	Farmácia	6000
25	5	0	São Paulo	Administração	5000
35	7	1	Rio de Janeiro	Farmácia	10000
40	15	1	Rio de Janeiro	Administração	6000
45	25	1	Rio de Janeiro	Farmácia	7500
22	1	0	São Paulo	Farmácia	1740
34	7	0	Rio de Janeiro	Farmácia	7000
56	25	1	São Paulo	Administração	6500
19	0	1	Rio de Janeiro	Administração	1990
29	9	0	São Paulo	Administração	8000

Tabela de frequência

Formação	n_i	f_i
Farmácia	5	0,5
Administração	5	0,5
total	$n=10$	1

Tabela de frequência - Exemplo no R

No exemplo a seguir é criado o vetor *populacao* contendo 10 indivíduos, sendo armazenado o sexo (M - Masculino, F - Feminino).

Tabela de frequência no R (Frequência Absoluta)

```
populacao = c("F", "M", "M", "F", "M", "F", "M", "F",  
  ↪  "F", "F")  
freq_absoluta = table(populacao)  
print(freq_absoluta)
```

Tabela de frequência - Exemplo no R

No exemplo a seguir é criado o vetor *populacao* contendo 10 indivíduos, sendo armazenado o sexo (M - Masculino, F - Feminino).

Tabela de frequência no R (Frequência Absoluta)

```
populacao = c("F", "M", "M", "F", "M", "F", "M", "F",  
  ↪ "F", "F")  
freq_absoluta = table(populacao)  
print(freq_absoluta)
```

Ao executar o código percebemos que a função *table* retorna apenas uma tabela contendo a frequência absoluta.

Tabela de frequência - Exemplo no R (Frequência Relativa)

Uma forma de mostrar a frequência relativa é apresentada no código abaixo.

Tabela de frequência no R (Frequência Relativa)

```
populacao = c("F", "M", "M", "F", "M", "F", "M", "F",  
  ↪  "F", "F")  
freq_absoluta = table(populacao)  
freq_relativa = prop.table(freq_absoluta)  
print(freq_relativa)
```

Tabela de frequência - Exemplo no R (Frequência Relativa)

Uma forma de mostrar a frequência relativa é apresentada no código abaixo.

Tabela de frequência no R (Frequência Relativa)

```
populacao = c("F", "M", "M", "F", "M", "F", "M", "F",  
  ↪  "F", "F")  
freq_absoluta = table(populacao)  
freq_relativa = prop.table(freq_absoluta)  
print(freq_relativa)
```

Atenção: Perceba que no código acima, a função que gera a tabela de frequência relativa (*prop.table*) recebe como argumento a própria tabela de frequência absoluta.

Tabela de frequência - Frequência Acumulada

Uma coluna que pode ser útil dentro de uma tabela de frequência é a coluna referente à frequência acumulada.

Denotaremos a frequência acumulada por f_{ac} , sendo obtida pela soma acumulada da coluna de frequência relativa (f_i).

frametitleFrequencia acumulada - Exemplo no R Para obter a frequência acumulada, basta usar a função *cumsum* do R

Tabela de frequência no R (Frequência Acumulada)

```
populacao = c("F", "M", "M", "F", "M", "F", "M", "F",  
  ↪ "F", "F")  
freq_absoluta = table(populacao)  
freq_relativa = prop.table(freq_absoluta)  
freq_acumulada = cumsum(freq_relativa)
```

Tabela de frequência com divisão em classes

Exemplo 5: Pense na construção uma tabela de frequência para a variável *Idade* da base de dados adotada no curso.

Será que usar uma tabela de frequência é a melhor forma de apresentar esses dados?

Frequência com divisão em classes

A tabela de frequência com divisão em classes é semelhante à tabela de frequência, mas com a diferença que os dados são agrupados em intervalos numéricos.

Frequência com divisão em classes

A tabela de frequência com divisão em classes é semelhante à tabela de frequência, mas com a diferença que os dados são agrupados em intervalos numéricos.

- Geralmente a divisão em classes é bastante útil para estudar variáveis quantitativas contínuas, pois geralmente os valores não se repetem.
- Tomemos como exemplo a variável salário da tabela vista anteriormente, nela apenas o valor 6000 se repete, todos os demais são únicos. Se construíssemos uma tabela de frequência comum, a maior parte dos valores teria frequência absoluta igual a 1.

Frequência com divisão em classes

Exemplo 6: Em uma turma do curso de Engenharia foi feito o registro da idade de cada um dos estudantes dessa turma

22	23	44	33	20	27	19	54	37	22
25	29	40	23	20	30	24	39	28	21

Construa uma tabela de frequência partindo da menor idade para a variável idade. Defina a amplitude como sendo igual a 5 e inclua apenas o limite inferior dos intervalos.

Frequência com divisão em classes

Exemplo 7: Em uma turma do curso de Engenharia foi feito o registro da idade de cada um dos estudantes dessa turma

22	23	44	33	20	27	19	54	37	22
25	29	40	23	20	30	24	39	28	21

Construa uma tabela de frequência partindo da menor idade para a variável idade. Defina a amplitude como sendo igual a 5 e inclua apenas o limite inferior dos intervalos.

Tabela de frequência com divisão em classes

Idade	n_i	f_i	f_{ac}
[19, 24)	8	0,4	0,4
[24, 29)	4	0,2	0,6
[29, 34)	3	0,15	0,75
[34, 39)	1	0,05	0,8
[39, 44)	2	0,1	0,9
[44, 49)	1	0,05	0,95
[49, 54)	0	0	0,95
[54, 59)	1	0,05	1
total	n=20	1	

Tabela de frequência com divisão em classes

- Como determinar a **amplitude dos intervalos**?

Tabela de frequência com divisão em classes

- Como determinar a **amplitude dos intervalos**?
- Todos os intervalos devem possuir a mesma amplitude?

Tabela de frequência com divisão em classes

- Como determinar a **amplitude dos intervalos**?
- Todos os intervalos devem possuir a mesma amplitude?
- Devemos usar intervalos abertos, semi-abertos ou fechados?

Tabela de frequência com divisão em classes - Exemplo no R

No exemplo a seguir, iremos construir uma tabela de frequência com divisão em classes para a variável idade, definindo a amplitude como sendo igual a 5 e incluindo apenas o limite inferior dos intervalos.

Tabela de frequência com divisão em classes no R (Amplitudes Iguais)

```
require("readxl")  
dados = read_excel(file.choose(), sheet=1)  
idades = dados$Idade  
tabela_freq = table(cut(idades, seq(min(idades),  
  ↪ max(idades), 5)))
```

Tabela de frequência com divisão em classes - Exemplo no R

No exemplo do slide anterior, utilizamos a função *cut* passando como segundo argumento uma sequência. Podemos também passar como argumento o número de intervalos, dessa forma a própria função define a amplitude.


Tabela de frequência com divisão em classes no R (Amplitudes Iguais)

```
require("readxl")  
dados = read_excel(file.choose(), sheet=1)  
idades = dados$Idade  
tabela_freq = table(cut(idades, 6))
```

Note que ao rodar o código acima temos 6 intervalos, não necessariamente de mesma amplitude.

Gráficos - Gráfico de dispersão

O gráfico de dispersão permite representar dados de duas ou três variáveis. Consiste em basicamente em dispor cada ponto no plano cartesiano.



Interpretação - Gráfico de dispersão

Em geral, a interpretação de um gráfico de dispersão se concentra em avaliar o comportamento de uma variável em relação à outra. Na Figura do slide anterior, podemos observar que **parece** que ao aumentar a idade, também há o aumento da duração do sono.

Gráficos - Gráfico de dispersão - Exemplo no R


Gráfico de dispersão no R

```
require("readxl")
dados = read_excel(file.choose(), sheet=1)
duracao_sono = dados$`Duracao do Sono`
idade = dados$Idade
plot(x=idade, y=duracao_sono,
     main="Duracao do Sono X Idade",
     xlab = "Idade", ylab = "Duracao do Sono",
     bg = "#87ceeb", # Cor dos pontos
     cex = 1.5, # Tamanho dos pontos
     pch=21) # Tipo do ponto
```

Gráficos - Gráfico de setores (pizza)

Consiste em dividir um círculo (pizza) em diferentes setores (fatias), cada um representando a proporção do elemento analisado em relação ao conjunto de estudo.

Proporcao de Individuos por Sexo



Atenção: Olhando para o gráfico do slide anterior, qual sexo parece ter maior proporção?

Atenção: Olhando para o gráfico do slide anterior, qual sexo parece ter maior proporção?

Devido a esse problema, recomenda-se evitar o uso de gráficos de pizza. Sendo recomendado:

- Colocar as porcentagens por extenso caso existam poucas categorias.
- Usar outro gráfico, como por exemplo o gráfico de barras.

Gráficos - Gráfico de setores (pizza) - Exemplo no R

Gráfico de pizza no R

```
require("readxl")
dados = read_excel(file.choose(), sheet=1)
sexo = dados$Sexo
freq_sexo = table(sexo)
pie(freq_sexo,
    border="white", # Coloca bordas brancas
    col=c("#60B5FF", "#FF9149"), # Cor de cada fatia
    main = "Proporcao de Indivíduos por Sexo")
```

Gráficos - Gráfico de barras


- Utiliza o plano cartesiano com os valores da variável no eixo das abcissas e as frequências ou porcentagens no eixo das ordenadas.

Gráficos - Gráfico de barras

- Utiliza o plano cartesiano com os valores da variável no eixo das abcissas e as frequências ou porcentagens no eixo das ordenadas.
- Utilizado, geralmente, para representar visualmente uma tabela de frequência.

Gráficos - Gráfico de barras

- Utiliza o plano cartesiano com os valores da variável no eixo das abcissas e as frequências ou porcentagens no eixo das ordenadas.
- Utilizado, geralmente, para representar visualmente uma tabela de frequência.



Interpretação - Gráfico de barras

- No gráfico de barras, estamos interessados em entender a altura da barra referente a cada categoria analisada.

Interpretação - Gráfico de barras

- No gráfico de barras, estamos interessados em entender a altura da barra referente a cada categoria analisada.
- Na Figura do slide anterior, podemos perceber que **parece** que temos a mesma proporção de indivíduos com apnea do sono e insônia, sendo o fato de não ter nenhum distúrbio a Característica maioritariamente presente no conjunto de dados.

Gráficos - Gráfico de barras - Exemplo no R

Gráfico de barras no R

```
require("readxl")
dados = read_excel(file.choose(), sheet=1)
disturbio_sono = dados$`Disturbio do Sono`
freq_disturbio = table(disturbio_sono)
barplot(freq_disturbio,
        main="Porporcao de Inidviduos por Disturbio
        ↪ do Sono",
        border="#60B5FF", # Cor do contorno das barras
        col="#87ceeb") # Cor das barras
```

Gráficos - Histograma

- O histograma é bastante semelhante ao gráfico de barras.

Gráficos - Histograma


- O histograma é bastante semelhante ao gráfico de barras.
- Utilizado, em geral, como uma representação visual da uma tabela agrupada em classes.

Gráficos - Histograma

- O histograma é bastante semelhante ao gráfico de barras.
- Utilizado, em geral, como uma representação visual da uma tabela agrupada em classes.
- Evidencia a distribuição de uma variável quantitativa.

Gráficos - Histograma

- O histograma é bastante semelhante ao gráfico de barras.
- Utilizado, em geral, como uma representação visual da uma tabela agrupada em classes.
- Evidencia a distribuição de uma variável quantitativa.



Interpretação - Histograma

- Ao olhar para um histograma estamos interessados em analisar a distribuição dos valores, tentando perceber a concentração dos valores para a variável analisada.

Interpretação - Histograma

- Ao olhar para um histograma estamos interessados em analisar a distribuição dos valores, tentando perceber a concentração dos valores para a variável analisada.
- Uma outra possibilidade é tentar identificar algum padrão, podendo relacionar com distribuições estatísticas conhecidas.
- Na Figura do slide anterior, podemos perceber que há uma maior concentração de frequências cardíacas antes do valor 72 batimentos por minuto.

Gráficos - Histograma - Exemplo no R

Histograma no R

```
require("readxl")  
dados = read_excel(file.choose(), sheet=1)  
freq_cardiaca = dados$`Frequencia Cardiaca`  
hist(freq_cardiaca,  
      main="Histograma da Frequencia Cardiaca",  
      xlab = "Frequencia Cardiaca",  
      ylab = "Frequencia",  
      breaks=8, # Numero de barras (Nem sempre)  
      col="#33CC8080", # Cor das barras  
      border=FALSE) # Elimina as bordas
```

Gráficos - Histograma

- O argumento breaks define o número de barras, entretanto, para esse gráfico, todas as barras devem ter o mesmo tamanho.

Gráficos - Histograma


- O argumento `breaks` define o número de barras, entretanto, para esse gráfico, todas as barras devem ter o mesmo tamanho.
- Também é possível passar uma tabela de frequência em classes dentro da função.

Gráficos - Boxplot


De forma inicial, o gráfico Boxplot apresenta a distribuição dos dados, mas, diferentemente do histograma, apresenta alguns elementos específicos, os quais serão vistos posteriormente.

Gráficos - Boxplot


De forma inicial, o gráfico Boxplot apresenta a distribuição dos dados, mas, diferentemente do histograma, apresenta alguns elementos específicos, os quais serão vistos posteriormente.




Gráficos - Exemplos a não serem seguidos




Gráficos - Exemplos a não serem seguidos




Gráficos - Exemplos a não serem seguidos



Gráficos - Exemplos a não serem seguidos



Gráficos - Exemplos a não serem seguidos



Gráficos - Exemplos a não serem seguidos



Medidas de Posição

Podemos ter o interesse em resumir nosso conjunto de dados, apresentando um ou mais valores que de certa forma representem todo o conjunto de dados.

Para determinar esses valores, utiliza-se as **medidas de posição central**: Média, Mediana e Moda.

Média Aritmética

Dado um conjunto de n observações $x_1, x_2, \dots, x_n$ a média aritmética é definida como:

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{x_1 + \dots + x_n}{n}$$

Média Aritmética

Exemplo 8: Suponha que tenhamos coletado a altura de 10 alunos de uma turma, as alturas obtidas foram as seguintes:

1,90; 1,67; 1,87; 1,55; 1,76; 1,87; 1,95; 1,66; 1,75; 1,60

Logo,

$$\bar{x} = \frac{1,90 + 1,67 + 1,87 + 1,55 + 1,76 + 1,87 + 1,95 + 1,66 + 1,75 + 1,60}{10} = 1,76$$

Média Aritmética - Exemplo no R

Para calcular a média de um conjunto de dados no R, utilizamos a função *mean*.

Calculando a Média Aritmética no R

```
altura = c(1.90, 1.67, 1.87, 1.55, 1.76, 1.87, 1.95,  
  ↪ 1.66, 1.75, 1.60)  
media_altura = mean(altura)
```

Moda

A moda de um conjunto de dados, representada por x^* , é o valor que mais se repete, ou seja, o valor mais frequente.

Moda

A moda de um conjunto de dados, representada por x^* , é o valor que mais se repete, ou seja, o valor mais frequente.

Atenção: Um conjunto de dados pode ter mais de uma moda.

Mediana

Seja $x_1, x_2, \dots, x_n$ um conjunto de n observações, e seja $x_{(i)}, i = 1, \dots, n$ o conjunto das observações ordenadas, de modo que $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$. Então, a mediana Q_2 é definida como o valor tal que 50% das observações são menores e 50% são maiores que ela.

Mediana

Seja $x_1, x_2, \dots, x_n$ um conjunto de n observações, e seja $x_{(i)}, i = 1, \dots, n$ o conjunto das observações ordenadas, de modo que $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$. Então, a mediana Q_2 é definida como o valor tal que 50% das observações são menores e 50% são maiores que ela.

Exemplo 10:

Suponhamos que o peso de 7 crianças de uma determinada turma escolar tenha sido coletada, os pesos coletados são exibidos a seguir:

28, 34, 45, 39, 42, 33, 50

Obtenha a mediana desse conjunto de dados

Mediana

Primeiramente vamos ordenar os dados:

28, 33, 34, 39, 42, 45, 50

Mediana

Primeiramente vamos ordenar os dados:

28, 33, 34, 39, 42, 45, 50

Logo, a mediana será o valor 39

Mediana

Exemplo 11: Retomemos o exemplo das alturas dos alunos, temos os seguintes dados:

1, 90; 1, 67; 1, 87; 1, 55; 1, 76; 1, 87; 1, 95; 1, 66; 1, 75; 1, 60

Para calcular a mediana, primeiramente vamos ordenar os dados:

1, 55; 1, 60; 1, 66; 1, 67; 1, 75; 1, 76; 1, 87; 1, 87; 1, 90; 1, 95

Mediana

Exemplo 12: Retomemos o exemplo das alturas dos alunos, temos os seguintes dados:

1, 90; 1, 67; 1, 87; 1, 55; 1, 76; 1, 87; 1, 95; 1, 66; 1, 75; 1, 60

Para calcular a mediana, primeiramente vamos ordenar os dados:

1, 55; 1, 60; 1, 66; 1, 67; 1, 75; 1, 76; 1, 87; 1, 87; 1, 90; 1, 95

Temos 10 elementos, logo, não conseguimos encontrar o valor que divide exatamente ao meio o conjunto de dados, nesse caso, a mediana é dada pela média dos elementos que ocupam a posição $\frac{n}{2}$ e $\frac{n}{2} + 1$.

Mediana

Portanto,

$$Q_2 = \begin{cases} x_{(\frac{n+1}{2})} & \text{se } n \text{ é ímpar} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2} & \text{se } n \text{ é par} \end{cases}$$

Médiana - Exemplo no R

Para obter a mediana de um conjunto de dados no R, basta usar a função *median*

Calculando a Mediana no R

```
require("readxl")  
dados = read_excel(file.choose(), sheet=1)  
idades = dados$Idade  
mediana_idade = median(idades)
```

Média X Mediana

- Imagine que você precisa atravessar um lago e existe uma placa que diz: Altura média do lago: 1,5 metros. Você o atravessaria?

Média X Mediana

- Imagine que você precisa atravessar um lago e existe uma placa que diz: Altura média do lago: 1,5 metros. Você o atravessaria?
- Dependendo do conjunto de dados, nem sempre a média é uma boa medida de resumo. A média é fortemente influenciada por valores aberrantes (outliers).

Média X Mediana

- Imagine que você precisa atravessar um lago e existe uma placa que diz: Altura média do lago: 1,5 metros. Você o atravessaria?
- Dependendo do conjunto de dados, nem sempre a média é uma boa medida de resumo. A média é fortemente influenciada por valores aberrantes (outliers).

Exemplo 15: Os seguintes dados referentes aos salários (em R\$) de cinco funcionários de uma firma:

136; 210; 350; 360; 2500

Calcule o salário médio.

Média X Mediana

No caso do slide anterior, o salário médio é igual a $R\$711,20$. No entanto, esse valor não representa, de forma adequada, os salários mais baixos e os salários mais altos, isso porque o mais alto é muito diferente dos demais.

Média X Mediana

- Por outro lado, a mediana desse conjunto de dados é o valor 350, que indica que metade dos valores é menor que 350 e a outra metade maior.
- Ainda assim, não conseguimos capturar o quanto menor ou maior são.

Observações

- Quando a média é próxima a mediana dizemos que isso é um indicativo de que a amostra não apresenta pontos aberrantes (possíveis outliers).
- A média é fortemente influenciada pela presença de pontos aberrantes, enquanto a mediana não é.

Quartis - Elementos fundamentais

- O primeiro quartil, que indicaremos por Q_1 , deixa 25% das observações abaixo e 75% acima dele.

Quartis - Elementos fundamentais

- O primeiro quartil, que indicaremos por Q_1 , deixa 25% das observações abaixo e 75% acima dele.
- A mediana é o segundo quartil

Quartis - Elementos fundamentais

- O primeiro quartil, que indicaremos por Q_1 , deixa 25% das observações abaixo e 75% acima dele.
- A mediana é o segundo quartil
- O terceiro quartil, Q_3 , deixa 75% das observações abaixo e 25% acima dele.

Quartis - Elementos adicionais

- Amplitude Interquartil (AIQ) = $Q_3 - Q_1$

Quartis - Elementos adicionais

- Amplitude Interquartil (AIQ) = $Q_3 - Q_1$
- Limite Superior = $Q_3 + 1,5 \cdot AI$

Quartis - Elementos adicionais

- Amplitude Interquartil (AIQ) = $Q_3 - Q_1$
- Limite Superior = $Q_3 + 1,5 \cdot AI$
- Limite Inferior = $Q_1 - 1,5 \cdot AI$

Quartis - Cálculo dos quartis

$$Q_1 = x_{(\frac{1}{4}(n+1))}$$

Quartis - Cálculo dos quartis

$$Q_1 = x_{(\frac{1}{4}(n+1))}$$

$$Q_3 = x_{(\frac{3}{4}(n+1))}$$

Importante: Se o valor obtido não for um inteiro, fazer uma média do elemento que ocupa a parte inteira e seu sucessor.


Quartis - Exemplo no R

Para obter os quartis de um conjunto de dados no R, utilizamos a função *quantile*.

Variância no R

```
require("readxl")
dados = read_excel(file.choose(), sheet=1)
duracao_sono = dados$`Duracao do Sono`
q1 = quantile(duracao_sono, 0.25) # Primeiro quartil
q3 = quantile(duracao_sono, 0.75) # Terceiro quartil
```

Revisitando o Boxplot



Boxplot - Exemplo no R

Gráfico Boxplot no R

```
require("readxl")
dados = read_excel(file.choose(), sheet=1)
disturbio_sono = dados$`Disturbio do Sono`
duracao_sono = dados$`Duracao do Sono`
boxplot(duracao_sono ~ disturbio_sono,
        col=c("#60B5FF", "#FF9149", "#33CC8080"))
```

Medidas de dispersão

Muitas vezes estamos interessados em entender o comportamento dos dados e as medidas de posição não são suficientes:

Exemplo 16: Calcule a média dos seguintes conjuntos de dados:

$$salarios_1 = 2.000,00; 3.500,00; 4.900,00; 3.100,00$$

$$salarios_2 = 3.375,00; 3.375,00; 3.375,00; 3.375,00$$

Medidas de dispersão

Exemplo 17: Calcule a mediana dos seguintes conjuntos de dados:

$$\text{salarios}_1 = 2.000,00; 3.500,00; 4.900,00; 3.100,00; 4.100,00$$

$$\text{salarios}_2 = 2.000,00; 3.500,00; 70.900,00; 3.100,00; 32.000,00$$

Em ambos os casos anteriores, percebemos que a Média e Mediana não são suficientes para descrever o comportamento dos dados. Devido a isso, trabalharemos agora com medidas de dispersão, sendo elas: Amplitude, Desvio médio absoluto, Variância, Desvio Padrão e Coeficiente de Variação.

Desvio médio absoluto

O desvio médio absoluto de um conjunto de dados $x_1, x_2, \dots, x_n$ é definido por:

$$DMA(X) = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

Desvio médio absoluto

O desvio médio absoluto de um conjunto de dados $x_1, x_2, \dots, x_n$ é definido por:

$$DMA(X) = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

- O desvio médio tem como objetivo verificar quanto os valores, em média, estão se distanciando da média.

Desvio médio absoluto

O desvio médio absoluto de um conjunto de dados $x_1, x_2, \dots, x_n$ é definido por:

$$DMA(X) = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

- O desvio médio tem como objetivo verificar quanto os valores, em média, estão se distanciando da média.
- Note que o desvio médio absoluto é sempre um valor positivo.

Desvio médio absoluto

O desvio médio absoluto de um conjunto de dados $x_1, x_2, \dots, x_n$ é definido por:

$$DMA(X) = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

- O desvio médio tem como objetivo verificar quanto os valores, em média, estão se distanciando da média.
- Note que o desvio médio absoluto é sempre um valor positivo.

Exemplo 21: Calcule o desvio médio para os salários dos exemplos anteriores.

Variância

A variância σ^2 de um conjunto de dados $x_1, x_2, \dots, x_n$ é definida por

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

Variância

A variância σ^2 de um conjunto de dados $x_1, x_2, \dots, x_n$ é definida por

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

- Perceba que a variância é bastante semelhante ao desvio médio absoluto, no entanto, penaliza grandes desvios.

Variância

A variância σ^2 de um conjunto de dados $x_1, x_2, \dots, x_n$ é definida por

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

- Perceba que a variância é bastante semelhante ao desvio médio absoluto, no entanto, penaliza grandes desvios.
- Observe que a variância é sempre um número **positivo**.

Variância

A variância σ^2 de um conjunto de dados $x_1, x_2, \dots, x_n$ é definida por

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

- Perceba que a variância é bastante semelhante ao desvio médio absoluto, no entanto, penaliza grandes desvios.
- Observe que a variância é sempre um número **positivo**.
- Note que a variância **não** fornece um valor na mesma unidade de medida dos dados.

Variância

A variância σ^2 de um conjunto de dados $x_1, x_2, \dots, x_n$ é definida por

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

- Perceba que a variância é bastante semelhante ao desvio médio absoluto, no entanto, penaliza grandes desvios.
- Observe que a variância é sempre um número **positivo**.
- Note que a variância **não** fornece um valor na mesma unidade de medida dos dados.
- A variância não tem interpretação prática direta, podendo ser utilizada como comparação.

Variância

Exemplo 22: Calcule a variância para os salários dos exemplos anteriores.

Variância - Exemplo no R

Para calcular a variância de um conjunto de dados no R, utilizamos a função *var*.

Variância no R

```
require("readxl")  
dados = read_excel(file.choose(), sheet=1)  
duracao_sono = dados$`Duracao do Sono`  
var_duracao_sono = var(duracao_sono)
```

Desvio padrão

O desvio padrão de um conjunto de dados $x_1, x_2, \dots, x_n$ é definido como a raiz quadrada da variância:

Desvio padrão

O desvio padrão de um conjunto de dados $x_1, x_2, \dots, x_n$ é definido como a raiz quadrada da variância:

$$\sigma = \sqrt{\sigma^2}$$

Desvio padrão

O desvio padrão de um conjunto de dados $x_1, x_2, \dots, x_n$ é definido como a raiz quadrada da variância:

$$\sigma = \sqrt{\sigma^2}$$

- Diferentemente da variância, o desvio padrão possui interpretação prática, pois ele volta o valor para a unidade de medida dos dados.

Desvio padrão

O desvio padrão de um conjunto de dados $x_1, x_2, \dots, x_n$ é definido como a raiz quadrada da variância:

$$\sigma = \sqrt{\sigma^2}$$

- Diferentemente da variância, o desvio padrão possui interpretação prática, pois ele volta o valor para a unidade de medida dos dados.
- Interpretamos o desvio padrão como quanto, em média, os valores do conjunto de dados estão se distanciando da média.

Desvio padrão

O desvio padrão de um conjunto de dados $x_1, x_2, \dots, x_n$ é definido como a raiz quadrada da variância:

$$\sigma = \sqrt{\sigma^2}$$

- Diferentemente da variância, o desvio padrão possui interpretação prática, pois ele volta o valor para a unidade de medida dos dados.
- Interpretamos o desvio padrão como quanto, em média, os valores do conjunto de dados estão se distanciando da média.
- Note que, apesar de interpretável, é difícil dizer se temos um desvio padrão alto ou baixo, mas, com o auxílio da amplitude, podemos tirar boas conclusões.

Coeficiente de variação

Dado um conjunto de observações $x_1, x_2, \dots, x_n$; o coeficiente de variação (CV) é definido como a razão entre o desvio-padrão dos dados e sua média, ou seja,

$$CV = \frac{\sigma}{\bar{x}}$$

- Em geral, multiplica-se o valor do CV por 100 para ter um valor percentual.

Coeficiente de variação

Dado um conjunto de observações $x_1, x_2, \dots, x_n$; o coeficiente de variação (CV) é definido como a razão entre o desvio-padrão dos dados e sua média, ou seja,

$$CV = \frac{\sigma}{\bar{x}}$$

- Em geral, multiplica-se o valor do CV por 100 para ter um valor percentual.
- Quanto menor for o valor do CV, mais homogêneo é um conjunto de dados.

Coeficiente de variação

Podemos adotar o seguinte critério:

- $CV < 0,10 \implies$ variabilidade baixa
- $0,10 \leq CV < 0,20 \implies$ variabilidade intermediária
- $0,20 \leq CV < 0,30 \implies$ variabilidade alta
- $CV \geq 0,30 \implies$ variabilidade muito alta

Observação: Só podemos calcular o CV quando a média amostral for diferente de zero.

Escores padronizados

Suponhamos que tenha sido feito um estudo visando entender o desempenho dos alunos do curso de Administração no curso de Cálculo em comparação com o curso de Estatística.

Escores padronizados

Suponhamos que tenha sido feito um estudo visando entender o desempenho dos alunos do curso de Administração no curso de Cálculo em comparação com o curso de Estatística.

As notas de 9 alunos da turma foram coletadas e são apresentadas abaixo:

Aluno	1	2	3	4	5	6	7	8	9
Estatística	6	4	5	7	8	5	5	5	7
Cálculo	6	8	9	10	7	7	8	9	3

Olhando para as notas, será que tirar 6 em Estatística tem o mesmo "peso" que tirar 6 em Cálculo?

Escores Padronizados

Aluno	1	2	3	4	5	6	7	8	9
Estatística	6	4	5	7	8	5	5	5	7
Cálculo	6	8	9	10	7	7	8	9	3

Vamos calcular a média das notas de cada um dos cursos:

$$\bar{x}_E = \frac{6 + 4 + 5 + 7 + 8 + 5 + 5 + 5 + 7}{9} = \frac{52}{9} = 5,78$$

Escores Padronizados

Aluno	1	2	3	4	5	6	7	8	9
Estatística	6	4	5	7	8	5	5	5	7
Cálculo	6	8	9	10	7	7	8	9	3

Vamos calcular a média das notas de cada um dos cursos:

$$\bar{x}_E = \frac{6 + 4 + 5 + 7 + 8 + 5 + 5 + 5 + 7}{9} = \frac{52}{9} = 5,78$$

$$\bar{x}_C = \frac{6 + 8 + 9 + 10 + 7 + 7 + 8 + 9 + 3}{9} = \frac{67}{9} = 7,44$$

Escores Padronizados

Aluno	1	2	3	4	5	6	7	8	9
Estatística	6	4	5	7	8	5	5	5	7
Cálculo	6	8	9	10	7	7	8	9	3

Vamos calcular a média das notas de cada um dos cursos:

$$\bar{x}_E = \frac{6 + 4 + 5 + 7 + 8 + 5 + 5 + 5 + 7}{9} = \frac{52}{9} = 5,78$$

$$\bar{x}_C = \frac{6 + 8 + 9 + 10 + 7 + 7 + 8 + 9 + 3}{9} = \frac{67}{9} = 7,44$$

- Podemos perceber que, o aluno 1, por exemplo, ficou acima da média em Estatística, mas abaixo da média em Cálculo.

Escores Padronizados

Aluno	1	2	3	4	5	6	7	8	9
Estatística	6	4	5	7	8	5	5	5	7
Cálculo	6	8	9	10	7	7	8	9	3

Vamos calcular a média das notas de cada um dos cursos:

$$\bar{x}_E = \frac{6 + 4 + 5 + 7 + 8 + 5 + 5 + 5 + 7}{9} = \frac{52}{9} = 5,78$$

$$\bar{x}_C = \frac{6 + 8 + 9 + 10 + 7 + 7 + 8 + 9 + 3}{9} = \frac{67}{9} = 7,44$$

- Podemos perceber que, o aluno 1, por exemplo, ficou acima da média em Estatística, mas abaixo da média em Cálculo.
- Outra forma de verificar essa afirmação é por meio do **desvio**.

Escores Padronizados - Desvio

O desvio de uma observação x_i em torna da média é definido como:

$$d_i = x_i - \bar{x}$$

Escores Padronizados - Desvio

O desvio de uma observação x_i em torna da média é definido como:

$$d_i = x_i - \bar{x}$$

Calculando os desvios da nota do primeiro aluno, temos:

$$d_{E_1} = 6 - 5,78 = 0,22$$

$$d_{C_1} = 6 - 7,44 = -1,44$$

Escores Padronizados - Desvio

O desvio de uma observação x_i em torna da média é definido como:

$$d_i = x_i - \bar{x}$$

Calculando os desvios da nota do primeiro aluno, temos:

$$d_{E_1} = 6 - 5,78 = 0,22$$

$$d_{C_1} = 6 - 7,44 = -1,44$$

- Dessa forma, temos que o aluno 1 ficou, aproximadamente, 0,22 pontos acima da média em Cálculo e 1,44 abaixo da média em Estatística.

Escores Padronizados - Desvio

O desvio de uma observação x_i em torna da média é definido como:

$$d_i = x_i - \bar{x}$$

Calculando os desvios da nota do primeiro aluno, temos:

$$d_{E_1} = 6 - 5,78 = 0,22$$

$$d_{C_1} = 6 - 7,44 = -1,44$$

- Dessa forma, temos que o aluno 1 ficou, aproximadamente, 0,22 pontos acima da média em Cálculo e 1,44 abaixo da média em Estatística.
- Ainda assim, não temos como comparar se o desempenho do aluno foi melhor em Estatística ou em Cálculo, pois, novamente, as médias são diferentes.

Escores Padronizados

Aluno	1	2	3	4	5	6	7	8	9
Estatística	6	4	5	7	8	5	5	5	7
Cálculo	6	8	9	10	7	7	8	9	3

Vamos calcular o desvio padrão das notas de cada um dos cursos.

$$\sigma_E^2 = 1,51 \implies \sigma_E = 1,23$$

Escores Padronizados

Aluno	1	2	3	4	5	6	7	8	9
Estatística	6	4	5	7	8	5	5	5	7
Cálculo	6	8	9	10	7	7	8	9	3

Vamos calcular o desvio padrão das notas de cada um dos cursos.

$$\sigma_E^2 = 1,51 \implies \sigma_E = 1,23$$

$$\sigma_C^2 = 3,80 \implies \sigma_C = 1,95$$

Escores Padronizados

Aluno	1	2	3	4	5	6	7	8	9
Estatística	6	4	5	7	8	5	5	5	7
Cálculo	6	8	9	10	7	7	8	9	3

Vamos calcular o desvio padrão das notas de cada um dos cursos.

$$\sigma_E^2 = 1,51 \implies \sigma_E = 1,23$$

$$\sigma_C^2 = 3,80 \implies \sigma_C = 1,95$$

- Qual disciplina apresenta maior variabilidade das notas?

Escores Padronizados

Aluno	1	2	3	4	5	6	7	8	9
Estatística	6	4	5	7	8	5	5	5	7
Cálculo	6	8	9	10	7	7	8	9	3

Vamos calcular o desvio padrão das notas de cada um dos cursos.

$$\sigma_E^2 = 1,51 \implies \sigma_E = 1,23$$

$$\sigma_C^2 = 3,80 \implies \sigma_C = 1,95$$

- Qual disciplina apresenta maior variabilidade das notas?
- Faça o cálculo da variância manualmente e verifique os resultados apresentados nesse slide.

Escores Padronizados

O escore padronizado de uma observação x_i é definido como:

$$z_i = \frac{x_i - \bar{x}}{\sigma_x}$$

Escores Padronizados

O escore padronizado de uma observação x_i é definido como:

$$z_i = \frac{x_i - \bar{x}}{\sigma_x}$$

- Ao dividirmos pelo desvio padrão, a escala passa a ser definida em termos do desvio padrão e cada escore padronizado nos informa que a observação está acima ou abaixo da média por um determinado número de desvios-padrão. Dessa forma, removemos o efeito das médias e o fato das variabilidades serem diferentes.
- **Importante:** A média dos escores padronizados é, independente do conjunto de dados, sempre igual a 0 e a variância igual a 1.

Escores Padronizados

Vamos analisar agora as notas de Estatística e Cálculo em termos dos escores padronizados:

Aluno	1	2	3	4	5	6	7	8	9
Estatística	Nota	6	4	5	7	8	5	5	7
	Escore	0,18	-1,45	-0,63	1,00	1,81	-0,63	-0,63	1,00
Cálculo	Nota	6	8	9	10	7	7	8	3
	Escore	-0,74	0,29	0,80	1,13	-0,23	-0,20	0,29	-3,28

- Podemos perceber que a nota 6 está, aproximadamente, 0,18 desvios-padrão acima da média em Estatística e aproximadamente 0,74 desvios-padrão abaixo da média das notas de Cálculo.
- Perceba que tirar a nota 10 em Cálculo é menos "surpreendente" que tirar 8 em Estatística.

Probabilidade

Espaço amostral

O espaço amostral, denotado pela letra grega Ω , é definido como o conjunto de todos os possíveis resultados de um experimento. Relacionando com os experimentos anteriores, temos:

Exemplo 23:

- 1) $\Omega = \{1, 2, 3, 4, 5, 6\}$
- 2) $\Omega = \{0, 1, 2, 3, 4\}$
- 3) $\Omega = \{0, 1, 2, 3, \dots, n\}$ onde n é o número máximo que pode ser produzido em 24 horas.
- 4) $\{t : t \geq 0\}$
- 5) $\{10, 11, 12, \dots\}$

Importante: O espaço amostral está sempre relacionado ao experimento

Espaço amostral

Exemplo 24: Uma caixa contém 3 bolas de gude: 1 vermelha, 1 verde e uma azul. Considere um experimento que consiste em retirar uma bola de gude da caixa, colocada de volta, em seguida outra bola é retirada. Descreva o espaço amostral.

Eventos

Um evento é simplesmente um subconjunto de um espaço amostral. Note que o próprio Ω é um evento. Relacionando com os espaços amostrais construídos anteriormente:

Exemplo 25:

- 1) Um número par ocorre, isto é, $A_1 = \{2, 4, 6\}$

Eventos

Um evento é simplesmente um subconjunto de um espaço amostral. Note que o próprio Ω é um evento. Relacionando com os espaços amostrais construídos anteriormente:

Exemplo 26:

- 1) Um número par ocorre, isto é, $A_1 = \{2, 4, 6\}$
- 2) $\{2\}$; isto é, duas caras ocorrem

Eventos

Um evento é simplesmente um subconjunto de um espaço amostral. Note que o próprio Ω é um evento. Relacionando com os espaços amostrais construídos anteriormente:

Exemplo 27:

- 1) Um número par ocorre, isto é, $A_1 = \{2, 4, 6\}$
- 2) $\{2\}$; isto é, duas caras ocorrem
- 3) $\{0\}$; isto é, todas as peças são perfeitas.

Eventos

Um evento é simplesmente um subconjunto de um espaço amostral. Note que o próprio Ω é um evento. Relacionando com os espaços amostrais construídos anteriormente:

Exemplo 28:

- 1) Um número par ocorre, isto é, $A_1 = \{2, 4, 6\}$
- 2) $\{2\}$; isto é, duas caras ocorrem
- 3) $\{0\}$; isto é, todas as peças são perfeitas.
- 4) $\{t : t < 3\}$; isto é, a lâmpada queima em menos de 3 horas.

Eventos

Um evento é simplesmente um subconjunto de um espaço amostral. Note que o próprio Ω é um evento. Relacionando com os espaços amostrais construídos anteriormente:

Exemplo 29:

- 1) Um número par ocorre, isto é, $A_1 = \{2, 4, 6\}$
- 2) $\{2\}$; isto é, duas caras ocorrem
- 3) $\{0\}$; isto é, todas as peças são perfeitas.
- 4) $\{t : t < 3\}$; isto é, a lâmpada queima em menos de 3 horas.
- 5) $\{0\}$; isto é, nenhuma peça defeituosa é fabricada.

Operações envolvendo eventos

Assim como vimos anteriormente, eventos são conjuntos, logo, tudo que vimos de teoria dos conjuntos pode ser também aplicado para eventos. Nesse sentido, definimos as seguintes operações:

- a) Se A e B forem eventos, $A \cup B$ será o evento que ocorrerá se, e somente se, A ou B (ou ambos) ocorrerem.

Operações envolvendo eventos

Assim como vimos anteriormente, eventos são conjuntos, logo, tudo que vimos de teoria dos conjuntos pode ser também aplicado para eventos. Nesse sentido, definimos as seguintes operações:

- a) Se A e B forem eventos, $A \cup B$ será o evento que ocorrerá se, e somente se, A ou B (ou ambos) ocorrerem.
- b) Se A e B forem eventos, $A \cap B$ será o evento que ocorrerá se, e somente se, A e B ocorrerem.

Operações envolvendo eventos

Assim como vimos anteriormente, eventos são conjuntos, logo, tudo que vimos de teoria dos conjuntos pode ser também aplicado para eventos. Nesse sentido, definimos as seguintes operações:

- a) Se A e B forem eventos, $A \cup B$ será o evento que ocorrerá se, e somente se, A ou B (ou ambos) ocorrerem.
- b) Se A e B forem eventos, $A \cap B$ será o evento que ocorrerá se, e somente se, A e B ocorrerem.
- c) Se A for um evento, A^c será o evento que ocorrerá se, e somente se, não ocorrer A .

Operações envolvendo eventos

Assim como vimos anteriormente, eventos são conjuntos, logo, tudo que vimos de teoria dos conjuntos pode ser também aplicado para eventos. Nesse sentido, definimos as seguintes operações:

- a) Se A e B forem eventos, $A \cup B$ será o evento que ocorrerá se, e somente se, A ou B (ou ambos) ocorrerem.
- b) Se A e B forem eventos, $A \cap B$ será o evento que ocorrerá se, e somente se, A e B ocorrerem.
- c) Se A for um evento, A^c será o evento que ocorrerá se, e somente se, não ocorrer A .
- d) Se $A_1, \dots, A_n$ for qualquer coleção finita de eventos, então $\bigcup_{i=1}^n A_i$ será o evento que ocorrerá se, e somente se, ao menos um dos eventos A_i ocorrer.

Operações envolvendo eventos

Assim como vimos anteriormente, eventos são conjuntos, logo, tudo que vimos de teoria dos conjuntos pode ser também aplicado para eventos. Nesse sentido, definimos as seguintes operações:

- a) Se A e B forem eventos, $A \cup B$ será o evento que ocorrerá se, e somente se, A ou B (ou ambos) ocorrerem.
- b) Se A e B forem eventos, $A \cap B$ será o evento que ocorrerá se, e somente se, A e B ocorrerem.
- c) Se A for um evento, A^c será o evento que ocorrerá se, e somente se, não ocorrer A .
- d) Se $A_1, \dots, A_n$ for qualquer coleção finita de eventos, então $\bigcup_{i=1}^n A_i$ será o evento que ocorrerá se, e somente se, ao menos um dos eventos A_i ocorrer.
- e) Se $A_1, \dots, A_n$ for qualquer coleção finita de eventos, então $\bigcap_{i=1}^n A_i$ será o evento que ocorrerá se, e somente se, todos os eventos A_i ocorrer.

Eventos mutuamente excludentes

Dois eventos, A e B , são denominados mutuamente excludentes se eles não puderem ocorrer juntos. Isso significa dizer que $A \cap B = \emptyset$.

Noção primitiva de probabilidade

Assumindo que todos os elementos do espaço amostral são equiprováveis, de forma ingênua, definidos a probabilidade de um evento A ocorrer da seguinte forma:

$$\mathbb{P}(A) = \frac{\text{número de elementos em } A}{\text{número de elementos em } \Omega}$$

Noção primitiva de probabilidade

Assumindo que todos os elementos do espaço amostral são equiprováveis, de forma ingênua, definidos a probabilidade de um evento A ocorrer da seguinte forma:

$$\mathbb{P}(A) = \frac{\text{número de elementos em } A}{\text{número de elementos em } \Omega}$$

Exemplo 32: Uma moeda honesta é lançada duas vezes, qual a probabilidade de sair duas caras?

Noção primitiva de probabilidade

Assumindo que todos os elementos do espaço amostral são equiprováveis, de forma ingênua, definidos a probabilidade de um evento A ocorrer da seguinte forma:

$$\mathbb{P}(A) = \frac{\text{número de elementos em } A}{\text{número de elementos em } \Omega}$$

Exemplo 34: Uma moeda honesta é lançada duas vezes, qual a probabilidade de sair duas caras?

Exemplo 35: Um dado de seis faces é lançado. Qual a probabilidade de sair um número maior do que 4?

Exemplo 36: Ao lançarmos dois dados de seis faces, qual a probabilidade da soma dos dois ser igual a sete?

Probabilidade como função

A noção primitiva de probabilidade nos diz como calcular probabilidades, mas não o que de fato é probabilidade.

Definição 1: Probabilidade, denotada por $\mathbb{P}$ é uma função que toma um evento $A \subset \Omega$ como entrada e retorna $\mathbb{P}(A) \in [0, 1]$ como saída. Essa função deve satisfazer as seguintes propriedades:

- 1) $\mathbb{P}(\Omega) = 1$
- 2) Para todo evento A , $\mathbb{P}(A) \geq 0$
- 3) Se A e B forem eventos mutuamente excludentes, então $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B)$
- 4) Seja $A_1, A_2, \dots, A_n$ uma sequência de eventos mutuamente exclusivos dois a dois, então $\mathbb{P}(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n \mathbb{P}(A_i)$

Probabilidade - Propriedades

A partir das propriedades definidas no slide anterior, podemos derivar outras propriedades. Sejam A e B eventos, logo temos que:

1) $\mathbb{P}(\emptyset) = 0$

Probabilidade - Propriedades

A partir das propriedades definidas no slide anterior, podemos derivar outras propriedades. Sejam A e B eventos, logo temos que:

1) $\mathbb{P}(\emptyset) = 0$

2) $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$

Probabilidade - Propriedades

A partir das propriedades definidas no slide anterior, podemos derivar outras propriedades. Sejam A e B eventos, logo temos que:

- 1) $\mathbb{P}(\emptyset) = 0$
- 2) $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$
- 3) Se $A \subset B$ então $\mathbb{P}(A) \leq \mathbb{P}(B)$

Probabilidade - Propriedades

A partir das propriedades definidas no slide anterior, podemos derivar outras propriedades. Sejam A e B eventos, logo temos que:

- 1) $\mathbb{P}(\emptyset) = 0$
- 2) $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$
- 3) Se $A \subset B$ então $\mathbb{P}(A) \leq \mathbb{P}(B)$
- 4) $0 \leq \mathbb{P} \leq 1$

Probabilidade - Propriedades

A partir das propriedades definidas no slide anterior, podemos derivar outras propriedades. Sejam A e B eventos, logo temos que:

- 1) $\mathbb{P}(\emptyset) = 0$
- 2) $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$
- 3) Se $A \subset B$ então $\mathbb{P}(A) \leq \mathbb{P}(B)$
- 4) $0 \leq \mathbb{P} \leq 1$
- 5) $\mathbb{P}(A \cap B^c) = \mathbb{P}(A) - \mathbb{P}(A \cap B)$

Probabilidade - Propriedades

A partir das propriedades definidas no slide anterior, podemos derivar outras propriedades. Sejam A e B eventos, logo temos que:

1) $\mathbb{P}(\emptyset) = 0$

2) $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$

3) Se $A \subset B$ então $\mathbb{P}(A) \leq \mathbb{P}(B)$

4) $0 \leq \mathbb{P} \leq 1$

5) $\mathbb{P}(A \cap B^c) = \mathbb{P}(A) - \mathbb{P}(A \cap B)$

6) $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$ *

* Princípio da inclusão-exclusão

Probabilidade - Interpretação Frequentista

Exemplo 37: De uma dada população, 42% são ruivos, 35% tem olhos azuis e 20% são ruivos de olhos azuis. Escolhendo ao acaso uma pessoa dessa população, qual a probabilidade de

- a) Ser ruivo ou ter olhos azuis?
- b) Não ser ruivo e ter olhos azuis?
- c) Ser ruivo mas não ter olhos azuis?

Sempre podemos calcular probabilidades?

Exemplo 38: Um lote contém peças pesando 5, 10, 15, 20, 25 gramas. Admitamos que ao menos duas peças de cada peso sejam encontradas no lote. Duas peças são retiradas do lote. Sejam X o peso da primeira peça escolhida e Y o peso da segunda.

- Determine o espaço amostral desse experimento.
- Determine a probabilidade de X ser igual a Y .

Probabilidade condicional

- A probabilidade de um evento ocorrer pode ser modificada ao descobrirmos novas informações que o afete.

Probabilidade condicional

- A probabilidade de um evento ocorrer pode ser modificada ao descobrirmos novas informações que o afete.
- Considere o experimento do lançamento de dois dados. Qual a probabilidade da soma dos resultados do lançamento dos dados dar 6 ?

Probabilidade condicional

- A probabilidade de um evento ocorrer pode ser modificada ao descobrirmos novas informações que o afete.
- Considere o experimento do lançamento de dois dados. Qual a probabilidade da soma dos resultados do lançamento dos dados dar 6 ?
- Digamos que o primeiro dado apresentou o número 3. Qual a probabilidade da soma dos resultados ser igual a 6?

Probabilidade condicional

- A probabilidade de um evento ocorrer pode ser modificada ao descobrirmos novas informações que o afete.
- Considere o experimento do lançamento de dois dados. Qual a probabilidade da soma dos resultados do lançamento dos dados dar 6 ?
- Digamos que o primeiro dado apresentou o número 3. Qual a probabilidade da soma dos resultados ser igual a 6?
- Digamos que um dos dados apresentou o número 3. Qual a probabilidade da soma dos valores ser um número par?

Probabilidade condicional

O problema proposto anteriormente é chamado de probabilidade condicional.

Definição 2: Sejam A e B dois eventos com $\mathbb{P}(B > 0)$. Dado que sabemos que B ocorreu, a probabilidade do evento A ocorrer pode ser definida como:

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

Probabilidade condicional

Uma editora lançou 360 livros e pode dividi-los entre ficção e não-ficção ou entre nacionais e internacionais segundo a tabela a seguir:

Origem \ Estilo	Ficção	Não-ficção	Total
Nacional	90	70	160
Internacional	120	80	200
Total	210	150	360

Table: Distribuição de livros por origem e estilo

Probabilidade condicional

Uma editora lançou 360 livros e pode dividi-los entre ficção e não-ficção ou entre nacionais e internacionais segundo a tabela a seguir:

Origem \ Estilo	Ficção	Não-ficção	Total
Nacional	90	70	160
Internacional	120	80	200
Total	210	150	360

Table: Distribuição de livros por origem e estilo

- Um livro é escolhido. Qual a probabilidade do livro escolhido ser nacional dado que é um livro não-ficcional.

Regra da multiplicação

Sejam A e B dois eventos com $\mathbb{P}(B) > 0$. Então vale:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A|B)\mathbb{P}(B) = \mathbb{P}(B|A)\mathbb{P}(A)$$

Atenção: Note que a regra da multiplicação é uma consequência direta da definição de probabilidade condicional.

Exemplo 39: Uma urna contém 4 bolinhas amarelas e 2 bolinhas verdes. Um experimento consiste em retirar uma bolinha, verificar sua cor e retirar uma segunda bolinha sem reposição. Calcule a probabilidade associada a cada resultado desse experimento.

Observação: Resolva usando a regra da multiplicação e o diagrama de árvore.

Regra da multiplicação

Podemos generalizar a regra da multiplicação para mais de 2 eventos:

Regra da multiplicação

Podemos generalizar a regra da multiplicação para mais de 2 eventos:

Sejam $A_1, A_2, \dots, A_n$ eventos num mesmo espaço amostral. Se $P(\cap_{i=1}^{n-1} A_i) > 0$, então:

$$\mathbb{P}(\cap_{i=1}^n A_i) = \mathbb{P}(A_1)\mathbb{P}(A_2|A_1) \cdot \dots \cdot \mathbb{P}(A_n|A_1, \dots, A_{n-1})$$

Particionamento do espaço amostral

Uma técnica que nos será útil a partir de agora é particionar (dividir) o espaço amostral em eventos **mutuamente excludentes** de tal forma que a união deles seja o próprio espaço amostral.

Particionamento do espaço amostral

Definição 3: Sejam A e B dois eventos em um mesmo espaço amostral:

$$\mathbb{P}(A) = \mathbb{P}(A|B)\mathbb{P}(B) + \mathbb{P}(A|B^c)\mathbb{P}(B^c)$$

Particionamento do espaço amostral

Exemplo 40: Em certo hospital especializado em doenças respiratórias, 75% dos pacientes são fumantes ou ex-fumantes e são indicados pelo código F, enquanto pacientes que nunca fumaram são indicados pelo código NF. Cerca de 60% dos pacientes do grupo F precisam de internação, enquanto apenas 20% dos não-fumantes são internados. Se escolhermos ao acaso um paciente que acabou de entrar no hospital, qual a probabilidade dele precisar de internação?

Particionamento do espaço amostral

Podemos generalizar essa noção para n eventos através do Teorema abaixo, conhecido como **Lei da Probabilidade Total**

Seja $\{B_1, \dots, B_n\}$ uma partição do espaço amostral Ω , onde, $\Omega = \bigcup_{i=1}^n B_i$, $\mathbb{P}(B_i) > 0$ e $\{B_1, \dots, B_n\}$ disjuntos dois a dois. Se A é um evento qualquer em Ω , vale:

$$\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A|B_i)\mathbb{P}(B_i)$$

Particionamento do espaço amostral

Exemplo 41: Suponha que um fabricante de sorvetes recebe 20% de todo o leite que utiliza em uma fazenda F_1 , 30% de uma outra fazenda F_2 e 50% de F_3 . Um órgão de fiscalização inspecionou as fazendas de surpresa e observou que 20% do leite produzido por F_1 estava adulterado por adição de água, enquanto para F_2 e F_3 , essa proporção era de 5% e 2%, respectivamente. Na indústria de sorvetes, os galões de leite são armazenados em um refrigerador sem identificação das fazendas.

- Qual a probabilidade do leite estar adulterado?

Teorema de Bayes

Sejam A e B dois eventos e $\mathbb{P}(B) > 0$. Então vale:

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(B|A)\mathbb{P}(A)}{\mathbb{P}(B)}$$

Teorema de Bayes

Exemplo 42: Em dado aeroporto, sabe-se que 90% dos pousos atrasam em dias de chuva e 15% nos dias que não chove. Seu amigo tem um voo com destino a esse aeroporto e a previsão de tempo disse que com probabilidade 0,4 estaria chovendo na região. Dado que o pouso está atrasado, qual a probabilidade de estar chovendo na região do aeroporto?

Teorema de Bayes

Exemplo 43: Suponha que um fabricante de sorvetes recebe 20% de todo o leite que utiliza em uma fazenda F_1 , 30% de uma outra fazenda F_2 e 50% de F_3 . Um órgão de fiscalização inspecionou as fazendas de surpresa e observou que 20% do leite produzido por F_1 estava adulterado por adição de água, enquanto para F_2 e F_3 , essa proporção era de 5% e 2%, respectivamente. Na indústria de sorvetes, os galões de leite são armazenados em um refrigerador sem identificação das fazendas.

- Qual é a probabilidade do leite ser proveniente da fazenda F_1 dado que o leite está adulterado?

Teorema de Bayes

Exemplo 44: Uma clínica envia amostras de uma certa substância para 3 laboratórios de análises A, B e C nas seguintes proporções 0,2; 0,3; 0,5 respectivamente. A probabilidade de cada um dos laboratórios elaborar uma análise errada é de $\frac{1}{2}$, $\frac{1}{3}$, $\frac{1}{6}$ respectivamente. Baseado nessas informações, pergunta-se:

- Qual é a probabilidade de um exame executado dar errado?
- Uma análise resultou errada, qual a probabilidade de ter sido feita pelo laboratório A? Pelo B? Pelo C?

Teorema de Bayes

Exemplo 45: Pelo fato de um novo procedimento médico ter se mostrado efetivo na detecção prévia de uma doença, propôs-se um rastreamento médico da população. A probabilidade do teste identificar corretamente alguém com a doença, dando positivo, é de 0,99 e a probabilidade do teste identificar corretamente alguém sem a doença, dando negativo, é de 0,95. A incidência da doença na população é 0,0001. Você fez o teste e o resultado foi positivo. Qual a probabilidade de você ter a doença?

Independência

Dizemos que dois eventos A e B definidos em um mesmo espaço amostral são independentes se:

$$\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$$

Independência

Exemplo 46: Suponha que a probabilidade de uma pessoa ser do tipo sanguíneo O é 0,45, ser A é 0,42 e ser B é 0,10. Suponha ainda que a probabilidade de Rh^+ é se 0,90 e que o fator independe do tipo sanguíneo. Nestas condições, qual a probabilidade de uma pessoa tomada ao acaso da população ser:

- O e Rh^+
- AB e RH^-

Variáveis aleatórias

Em muitos experimentos é útil trabalhar com uma "variável resumo".

Exemplo 47: Numa pesquisa de opinião, decidimos perguntar a 20 pessoas se elas concordam ou discordam sobre determinado assunto. Nessa pesquisa, anotaremos o valor 1 se a pessoa concorda e 0 se a pessoa discorda.

- Observe que o tamanho do espaço amostral desse experimento contém $2^{20} = 1048576$ elementos.
- Podemos estar interessados em características específicas em relação aos elementos do espaço amostral.

Variáveis aleatórias

Definição 4: Uma variável aleatória nada mais é que uma função que toma como entrada elementos do espaço amostral e gera como saída um número real

- Variáveis aleatórias serão denotadas em geral por letras maiúsculas do final do alfabeto: W, X, Y, Z

Variáveis aleatórias


Definição 5: Uma variável aleatória nada mais é que uma função que toma como entrada elementos do espaço amostral e gera como saída um número real

- Variáveis aleatórias serão denotadas em geral por letras maiúsculas do final do alfabeto: W, X, Y, Z
- Denotaremos por Ω_X o conjunto de possíveis valores assumidos pela Variável Aleatória X .

Variáveis aleatórias

Definição 6: Uma variável aleatória nada mais é que uma função que toma como entrada elementos do espaço amostral e gera como saída um número real

- Variáveis aleatórias serão denotadas em geral por letras maiúsculas do final do alfabeto: W, X, Y, Z
- Denotaremos por Ω_X o conjunto de possíveis valores assumidos pela Variável Aleatória X .
- **Atenção:** Note que X pode ser a função identidade, Ω_X é igual a Ω .



Variáveis aleatórias

Exemplo 48: Considere o experimento do lançamento de duas moedas. Nesse caso temos:

$$\Omega = \{(Cara, Cara), (Coroa, Coroa), (Cara, Coroa), (Coroa, Cara)\}$$

Definamos a variável aleatória X :Número de caras obtidas nas duas moedas. Dessa forma temos, $X((Cara, Cara)) = 2$, $X((Cara, Coroa)) = 1$, $X((Coroa, Cara)) = 1$, $X((Coroa, Coroa)) = 0$

Variáveis aleatórias discretas

Definição 7: Uma variável aleatória discreta é aquela que pode tomar apenas um número contável de valores, tais como $0, 1, 2, 3, 4, \dots$. Denotaremos por Ω_X o conjunto de possíveis valores que essa variável pode assumir.

- Variáveis aleatórias discretas geralmente estão relacionadas à contagem.

Variáveis aleatórias discretas

Exemplo 49: Se lançamos três dados de seis faces podemos definir, entre outras, as seguintes variáveis aleatórias discretas:

- X : A soma dos resultados:

$$\Omega_X = \{3, 4, 5, \dots, 16, 17, 18\}$$

- Y : X : O produto dos dois primeiros resultados:

$$\Omega_Y = \{1, 2, 3, 4, 5, 6, 8, 9, 10, 12, 15, 16, 18, 20, 24, 25, 30, 36\}$$

- Z : X : O máximo entre os resultados:

$$\Omega_Z = \{1, 2, 3, 4, 5, 6\}$$

Variáveis aleatórias discretas

Exemplo 50:

Experimento	Variável aleatória (x)	Valores possíveis para a variável aleatória
Contatar cinco clientes	Número de clientes que fazem um pedido de compra	0, 1, 2, 3, 4, 5
Inspecionar uma remessa de 50 rádios	Número de rádios com defeito	0, 1, 2, ..., 49, 50
Operar um restaurante por um dia	Número de clientes	0, 1, 2, 3, ...
Vender um automóvel	Gênero do cliente	0 se for homem; 1 se for mulher

Distribuição de uma variável aleatória discreta

A função de probabilidade de uma variável aleatória discreta é uma lista com as probabilidades associadas a cada possível valor que a variável assume. Também é chamada de função massa de probabilidade. Seja X uma variável aleatória que assume os valores $x_1, x_2, \dots, x_n$, utilizaremos a seguinte notação para representar essa função:

$$p(x_i) = \mathbb{P}(X = x_i)$$

Essa função deve satisfazer as seguintes propriedades:

- $p_X(x_i) \geq 0$ para todo i ,
- $\sum_{i=1}^n p_X(x_i) = 1$

Distribuição de uma variável aleatória discreta

Considere o experimento de lançar uma moeda honesta para o ar 3 vezes e anotar a sequência dos resultados

- Qual o espaço amostral desse experimento?

Distribuição de uma variável aleatória discreta

Considere o experimento de lançar uma moeda honesta para o ar 3 vezes e anotar a sequência dos resultados

- Qual o espaço amostral desse experimento?
- Definamos a variável aleatória Y : Número de caras obtidas, qual a função de probabilidade associada a essa variável?

Distribuição de uma variável aleatória discreta

Exemplo 51: Em um processo de fabricação de semicondutores, três pastilhas de um lote são testadas. Cada pastilha é classificada como "passa" ou "falha". Suponha que a probabilidade de uma pastilha passar no teste seja 0,8 e que as pastilhas sejam independentes. Seja a variável resposta X definida como o número de pastilhas de um lote que passa no teste.

- Defina o espaço amostral desse experimento
- Determine a função de probabilidade de X .

Função distribuição acumulada

Definição 8: Seja X uma variável aleatória, definiremos sua **Função distribuição acumulada** da seguinte forma:

$$F_X(x) = \mathbb{P}(X \leq x)$$

Função distribuição acumulada

Exemplo 52: Considere a variável aleatória X que representa o número de pedidos durante o período de 5 minutos em uma empresa de vendas online.

r	0	1	2	3	4	5	6
$Pr(X = r)$	0,129	0,264	0,271	0,185	0,095	0,039	0,017

Nesse caso:

Função distribuição acumulada

Exemplo 53: Considere a variável aleatória X que representa o número de pedidos durante o período de 5 minutos em uma empresa de vendas online.

r	0	1	2	3	4	5	6
$Pr(X = r)$	0,129	0,264	0,271	0,185	0,095	0,039	0,017

Nesse caso:

- $F_X(-1) = \mathbb{P}(X \leq -1) = 0$
- $F_X(0) = \mathbb{P}(X \leq 0) = \mathbb{P}(X = 0) = 0,129$
- $F_X(1) = \mathbb{P}(X \leq 1) = \mathbb{P}(X = 0) + \mathbb{P}(X = 1) = 0,129 + 0,264 = 0,393$
- $F_X(2) = \mathbb{P}(X \leq 2) = \mathbb{P}(X = 0) + \mathbb{P}(X = 1) + \mathbb{P}(X = 2) = 0,129 + 0,264 + 0,271 = 0,664$

Função distribuição acumulada

- $F_X(-1) = \mathbb{P}(X \leq -1) = 0$
- $F_X(0) = \mathbb{P}(X \leq 0) = \mathbb{P}(X = 0) = 0,129$
- $F_X(1) = \mathbb{P}(X \leq 1) = \mathbb{P}(X = 0) + \mathbb{P}(X = 1) = 0,129 + 0,264 = 0,393$
- $F_X(2) = \mathbb{P}(X \leq 2) = \mathbb{P}(X = 0) + \mathbb{P}(X = 1) + \mathbb{P}(X = 2) = 0,129 + 0,264 + 0,271 = 0,664$
- $\vdots$
- $F_X(6) = \mathbb{P}(X \leq 6) = 1$

Variável aleatória discreta

Exemplo 54:

Considere a variável aleatória X possuindo a seguinte função de probabilidade:

x	$p_X(x)$
20	0,20
25	0,15
30	0,25
35	0,40

- 1) Esta distribuição de probabilidade é válida? Explique.
- 2) Qual a probabilidade de X ser igual a 30?
- 3) Qual a probabilidade de X ser menor ou igual a 25?
- 4) Qual é a probabilidade de X ser maior que 30?

Imagine o seguinte jogo:

- O jogador aposta $R\$10,00$ e escolhe cara ou coroa
- Uma moeda honesta é jogado ao ar.
- Se a moeda mostrar o resultado cara, então o jogador ganhar $R\$10,00$. Caso contrário, perde os $R\$10,00$ apostados.

Imagine o seguinte jogo:

- O jogador aposta $R\$10,00$ e escolhe cara ou coroa
- Uma moeda honesta é jogado ao ar.
- Se a moeda mostrar o resultado cara, então o jogador ganhar $R\$10,00$. Caso contrário, perde os $R\$10,00$ apostados.

Esse jogo é justo?

Esperança Matemática para Variáveis Discretas

O valor esperado, média, ou esperança matemática é uma quantidade utilizada como resumo do comportamento de uma V.A.

$$\mathbb{E}[X] = \sum_{x_i \in \Omega_X} x_i \mathbb{P}(X = x_i)$$

Esperança Matemática para Variáveis Discretas

Historicamente, o conceito de esperança foi usado para verificar se jogos eram justos. Entretanto, esse conceito não se restringe apenas à esse campo.

Esperança Matemática para Variáveis Discretas

Historicamente, o conceito de esperança foi usado para verificar se jogos eram justos. Entretanto, esse conceito não se restringe apenas à esse campo.

Vamos verificar se o jogo proposto anteriormente é justo:

- Definamos X : ganho obtido no jogo.

Esperança Matemática para Variáveis Discretas

Historicamente, o conceito de esperança foi usado para verificar se jogos eram justos. Entretanto, esse conceito não se restringe apenas à esse campo.

Vamos verificar se o jogo proposto anteriormente é justo:

- Definamos X : ganho obtido no jogo.
- $\mathbb{E}[X] = 10 \cdot \frac{1}{2} - 10 \cdot \frac{1}{2} = 0$

Esperança Matemática para Variáveis Discretas

Historicamente, o conceito de esperança foi usado para verificar se jogos eram justos. Entretanto, esse conceito não se restringe apenas à esse campo.

Vamos verificar se o jogo proposto anteriormente é justo:

- Definamos X : ganho obtido no jogo.
- $\mathbb{E}[X] = 10 \cdot \frac{1}{2} - 10 \cdot \frac{1}{2} = 0$
- Portanto, o jogo é justo.

Esperança Matemática para Variáveis Discretas

Exemplo 55: Um jogo funciona da seguinte forma:

- O jogador deve pagar R\$10,00 para participar do jogo.
- Se a soma dos resultados dos dois dados for igual a 10, então o jogador ganha R\$200,00
- Se a soma dos resultados dos dois dados for igual a 7, então o jogador perde R\$100,00
- Se a soma dos resultados dos dois dados for um número primo diferente de 7, então o jogador ganha R\$100,00
- Se a soma dos resultados dos dois dados for um número não-primo diferente de 10, então o jogador perde R\$50,00

Sabendo disso, defina uma variável aleatória como sendo o ganho (ou perda) obtido pelo jogador, obtenha sua esperança

Esperança Matemática para Variáveis Discretas

Vamos jogar outro jogo:

- O jogador deve apostar x reais, com $x > 0$.

Esperança Matemática para Variáveis Discretas

Vamos jogar outro jogo:

- O jogador deve apostar x reais, com $x > 0$.
- Uma moeda honesta é jogado ao ar até que saia cara pela primeira vez.

Esperança Matemática para Variáveis Discretas

Vamos jogar outro jogo:

- O jogador deve apostar x reais, com $x > 0$.
- Uma moeda honesta é jogado ao ar até que saia cara pela primeira vez.
- O número de jogadas até sair cara (incluindo a própria rodada que saiu cara) é denotado por n .

Esperança Matemática para Variáveis Discretas

Vamos jogar outro jogo:

- O jogador deve apostar x reais, com $x > 0$.
- Uma moeda honesta é jogado ao ar até que saia cara pela primeira vez.
- O número de jogadas até sair cara (incluindo a própria rodada que saiu cara) é denotado por n .
- O jogador ganha $R\$: 2^n$

Esperança Matemática para Variáveis Discretas

Vamos jogar outro jogo:

- O jogador deve apostar x reais, com $x > 0$.
- Uma moeda honesta é jogado ao ar até que saia cara pela primeira vez.
- O número de jogadas até sair cara (incluindo a própria rodada que saiu cara) é denotado por n .
- O jogador ganha $R\$: 2^n$
- Qual o valor de x para que esse jogo seja justo?

Esperança Matemática para Variáveis Discretas

O jogo do slide anterior ficou conhecido como Paradoxo de São Petesburgo. Sua proposição provoca discussões que se estendem até os dias de hoje.

Esperança Matemática para Variáveis Discretas

Vamos sair um pouco do contexto dos jogos. Se eu jogo um dado simétrico de seis faces, definindo X : Resultado apresentado pelo dado.

Esperança Matemática para Variáveis Discretas

Vamos sair um pouco do contexto dos jogos. Se eu jogo um dado simétrico de seis faces, definindo X : Resultado apresentado pelo dado.

$$\mathbb{E}[X] = \sum_{s=1}^6 s \cdot \frac{1}{6} = 3,5$$

Esperança Matemática para Variáveis Discretas

Vamos sair um pouco do contexto dos jogos. Se eu jogo um dado simétrico de seis faces, definindo X : Resultado apresentado pelo dado.

$$\mathbb{E}[X] = \sum_{s=1}^6 s \cdot \frac{1}{6} = 3,5$$

Qual o significado do valor 3,5?

Variância de Variáveis Aleatórias

A variância representa o grau de dispersão de uma variável aleatória em relação a sua média ou esperança $\mathbb{E}[X]$. A forma geral para o cálculo é:

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

Uma forma alternativa de apresentar a variância é através da seguinte expressão:

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

onde

$$\mathbb{E}[X^2] = \sum_{x_i \in \Omega_X} x_i^2 \mathbb{P}(X = x_i)$$

Exemplos

Exemplo 56: Considere o experimento de lançar uma moeda honesta para o ar 5 vezes e anotar a sequência dos resultados

- Qual o espaço amostral desse experimento?
- Definamos a variável aleatória Y : Número de tentativas até obter a primeira cara, qual a função de probabilidade associada a essa variável?
- Calcule o valor esperado da variável Y .
- Calcule a variância da variável Y .

Exemplos

Exemplo 57: Em um processo de fabricação de semicondutores, três pastilhas de um lote são testadas. Cada pastilha é classificada como "passa" ou "falha". Suponha que a probabilidade de uma pastilha passar no teste seja 0,8 e que as pastilhas sejam independentes. Seja a variável resposta X definida como o número de pastilhas de um lote que passa no teste.

- Defina o espaço amostral desse experimento
- Determine a função de probabilidade de X .
- Determine o valor esperado de X .
- Determine a variância de X .

Outras medidas de dispersão

Também podemos calcular o desvio padrão de uma variável aleatória.

$$DP(X) = \sqrt{Var(X)}$$

Além disso, podemos calcular o coeficiente de variação

$$CV = \frac{DP(X)}{\mathbb{E}[X]}$$

Propriedades do Valor Esperado e Variância

$$\mathbb{E}[aX + b] = a\mathbb{E}[X] + b$$

$$\text{Var}(aX + b) = a^2 \text{Var}(X)$$

Sejam $X_1, X_2, \dots, X_n$ v.as independentes com $\mathbb{E}[X_i] < \infty$ então:

$$\mathbb{E}[X_1 + X_2 + \dots + X_n] = \mathbb{E}[X_1] + \mathbb{E}[X_2] + \dots + \mathbb{E}[X_n]$$

Distribuições de Probabilidade para Variáveis Aleatórias Discretas

Algumas variáveis aleatórias aparecem com bastante frequência em situações práticas e justificam um estudo mais aprofundado. Em geral, nesses casos, a **função de probabilidade** pode ser escrita de maneira mais compacta, isto é, existe uma lei para atribuir probabilidades.

As distribuições de probabilidade para variáveis discretas mais importantes são:

- Distribuição de Bernoulli
- Distribuição Binomial
- Distribuição de Poisson
- Distribuição Geométricas
- Distribuição Hipergeométrica
- Distribuição Binomial negativa

Distribuição de Bernoulli

Considere os seguintes experimentos:

- Lançamento de uma moeda
- Retirada de uma peça de um conjunto de 10 peças seguido pela verificação se a peça é defeituosa ou não
- Pesquisa de opinião se aprova ou não aprova a atual gestão da UFRJ.
- Um aluno realiza uma prova e em seguida verifica se passou ou não.
- Realização de inseminação artificial seguida pela verificação se ocorreu gravidez ou não.

O que esses experimentos tem em comum?

Distribuição de Bernoulli

Considere os seguintes experimentos:

- Lançamento de uma moeda
- Retirada de uma peça de um conjunto de 10 peças seguido pela verificação se a peça é defeituosa ou não
- Pesquisa de opinião se aprova ou não aprova a atual gestão da UFRJ.
- Um aluno realiza uma prova e em seguida verifica se passou ou não.
- Realização de inseminação artificial seguida pela verificação se ocorreu gravidez ou não.

O que esses experimentos tem em comum?

Todos os experimentos acima tem unicamente dois resultados possíveis. Sendo possível criar uma variável aleatória que associe cada resultado aos valores 1 e 0.

Distribuição de Bernoulli

A distribuição de probabilidade da variável aleatória X que segue distribuição de Bernoulli com parâmetro p é dada por.

x	$p_X(x)$
1	p
0	$1-p$

- Notação: $X \sim \text{Bernoulli}(p)$
- A função de probabilidade da distribuição Bernoulli é dada por:

$$p_X(x) = \mathbb{P}(X = x) = p^x(1 - p)^{1-x} \text{ para } x = 0, 1$$

Distribuição de Bernoulli

Valor Esperado

$$\mathbb{E}[X] = 1 \cdot p + 0 \cdot (1 - p) = p$$

Variância

$$\begin{aligned} \text{Var}(X) &= \mathbb{E}[X^2] - \mathbb{E}[X]^2 \\ &= p \cdot 1^2 + (1 - p) \cdot 0 - p^2 \\ &= p(1 - p) \end{aligned}$$

Distribuição de Bernoulli: Exemplo

Exemplo 58: Experimento: Lançamento de um dado
Definamos X : Verificação se o dado apresentou uma face menor que 3

Temos que:

- $X = 1$ se o resultado obtido for 1 ou 2
- $X = 0$ se o resultado obtido for 3, 4 ou 5

Função de probabilidade de X

Distribuição de Bernoulli: Exemplo

Exemplo 59: Experimento: Lançamento de um dado
Definamos X : Verificação se o dado apresentou uma face menor que 3

Temos que:

- $X = 1$ se o resultado obtido for 1 ou 2
- $X = 0$ se o resultado obtido for 3, 4 ou 5

Função de probabilidade de X

x	$p_X(x)$
1	2/6
0	4/6

Podemos dizer que $X \sim \text{Bernoulli}(1/3)$

Distribuição Binomial

- São realizados n ensaios de Bernoulli independentes
- Cada ensaio só pode ter dois resultados possíveis: sucesso ou fracasso
- A probabilidade p de sucesso em cada ensaio é a mesma

Vamos definir a variável aleatória X como sendo o número total de sucessos nos n ensaios de Bernoulli. Portanto, X poderá assumir os valores $0, 1, \dots, n$

Distribuição Binomial

Suponha que lancemos uma moeda n vezes. Como vimos, podemos construir uma variável aleatória associada a esse experimento que resulta em 1 caso a moeda de cara e 0 caso de coroa. Suponha que ocorra 1 apenas nos x primeiros ensaios e 0 nos $n - x$ ensaios restantes.

$$\underbrace{1, 1, 1, \dots, 1}_x, \underbrace{0, 0, 0, \dots, 0}_{n-x}$$

Como os ensaios são independentes, temos que:

$$\underbrace{p \cdot p \cdot p \cdots p}_x \cdot \underbrace{(1-p) \cdot (1-p) \cdot (1-p) \cdots (1-p)}_{n-x} = p^x (1-p)^{n-x}$$

Distribuição Binomial

Porém, o evento " x sucessos em n ensaios" pode ocorrer de diferentes ordens distintas, todas com a mesma probabilidade. Como o número de ordens é o número de combinações de n elementos escolhendo x , então a probabilidade de ocorrerem x sucessos em n ensaios de Bernoulli é representada por:

$$\mathbb{P}(X = x) = \binom{n}{x} p^x (1 - p)^{n-x}, x = 0, 1, \dots, n$$

Distribuição Binomial: Exemplo

Retira-se 3 cartas com reposição. Seja X o número de vezes que sai alguma carta de copas. Então $X \sim (3, 1/4)$.

$$\Omega_X = \{0, 1, 2, 3\}$$

$$\mathbb{P}(X = 2) = 3 \left(\frac{1}{4}\right)^2 \left(\frac{3}{4}\right)^1$$

- 3 : Número de formas de ter 2 cartas de copas em 3 tentativas
- 2 : Número de copas nas 3 tentativas
- 1 : Número de não-copas nas 3 tentativas
- Calcule $\mathbb{P}(X = 0)$

Distribuição Binomial

Valor Esperado e Variância: $\mathbb{E}[X] = np$ e $Var(X) = np(1 - p)$

Distribuição Binomial: Exemplo

Voltar ao exemplo das pastilhas.

Distribuição Binomial: Exemplo

Exemplo 60: Certo jogador de basquete costuma acertar 70% dos lançamentos na cesta. Esse jogador foi convidado para participar de um evento beneficente em que ele pode arrecadar um grande prêmio para uma instituição de sua escolha se ele fizer 10 lançamentos e acertar todos. Supondo que os lançamentos são independentes, qual a probabilidade de ele conseguir o prêmio?

Distribuição Binomial: Exemplo

Exemplo 61: Cada amostra de ar tem uma probabilidade de 10% de conter um determinado poluente orgânico. Considere 18 amostras que sejam independentes com relação à presença do poluente. Seja a variável aleatória X definida como o número de amostras de ar que contêm o poluente orgânico. pergunta-se:

- Qual a probabilidade de que exatamente duas amostras contenham o poluente
- Qual a probabilidade de que pelo menos 4 amostras contenham o poluente.

Distribuição de Poisson

Seja um experimento realizado nas seguintes condições:

- 1) As ocorrências são independentes
- 2) As ocorrências são aleatórias
- 3) A variável aleatória X é o número de ocorrências de um evento ao longo de algum intervalo

Vamos definir a variável aleatória X como sendo o número de ocorrências em um intervalo. Portanto, X poderá assumir os valores $0, 1, \dots$ (sem limite superior)

Distribuição de Poisson

Uma variável aleatória segue a distribuição de Poisson se sua função de probabilidade é dada por:

$$\mathbb{P}(X = x) = \frac{e^{-\lambda} \lambda^x}{x!}, \quad x = 0, 1, 2, \dots$$

em que o parâmetro $\lambda > 0$ representa a taxa média de ocorrência por unidade de medida (tempo, por exemplo)

Distribuição de Poisson

Notação: $X \sim \text{Poisson}(\lambda)$ Esperança e Variância:

$$\mathbb{E}[X] = \text{Var}(X) = \lambda$$

Exemplo: Distribuição de Poisson

Sabe-se que em média ocorrem 2 terremotos por semana em certa região do mundo. Numa dada semana, qual a probabilidade de ocorrerem 4 terremotos nessa região?

Exemplo: Distribuição de Poisson

Exemplo 62: Chamadas telefônicas são recebidas à taxa de 48 por hora no balcão de reservas da Regional Airways

- Calcule a probabilidade de serem recebidas três chamadas em um intervalo de cinco minutos?
- Calcule a probabilidade de serem recebidas exatamente 10 chamadas em 15 minutos.

Variáveis aleatórias contínuas

Uma variável aleatória é contínua se assume valores em qualquer intervalo dos números reais.

Dessa forma, não é possível atribuir probabilidades para um ponto específico, apenas para intervalos da reta.

Definição 9: Dize-se que X é uma variável aleatória contínua, se existir uma função f_X , denominada função densidade de probabilidade (fdp) de X que satisfaça as seguintes condições:

- 1) $f(x) \geq 0$ para todo x
- 2) $\int_{-\infty}^{\infty} f(x)dx = 1$

Variáveis aleatórias contínuas

Exemplos de variáveis aleatórias contínuas:

- Altura de estudantes em uma disciplina
- Intervalo de tempo entre chegadas de um ônibus
- Peso de pessoas
- Profundidade de lagos


Variáveis aleatórias contínuas

Nesse caso, temos:

$$\mathbb{P}(a \leq X \leq b) = \int_a^b f_X(x) dx$$

O que implica que

$$\mathbb{P}(X = a) = 0$$



$P(a \leq X \leq b) = \text{área da região sombreada}$

Variáveis aleatórias contínuas

Exemplo 63: Suponhamos que um ponto seja escolhido no intervalo $(0, 1)$. Representemos por X a variável aleatória cujo valor seja a abscissa x do ponto escolhido.

Seja $I \subset (0, 1)$, então $\mathbb{P}(X \in I)$ será diretamente proporcional ao comprimento de I .

Qual é a fdp de X ? Podemos encontrar uma função f tal que:

Variáveis aleatórias contínuas

Exemplo 64: Suponhamos que um ponto seja escolhido no intervalo $(0, 1)$. Representemos por X a variável aleatória cujo valor seja a abscissa x do ponto escolhido.

Seja $I \subset (0, 1)$, então $\mathbb{P}(X \in I)$ será diretamente proporcional ao comprimento de I .

Qual é a fdp de X ? Podemos encontrar uma função f tal que:

$$\mathbb{P}(a < X < b) = \int_a^b f(x) dx$$

Variáveis aleatórias contínuas

Exemplo 65: Suponhamos que um ponto seja escolhido no intervalo $(0, 1)$. Representemos por X a variável aleatória cujo valor seja a abscissa x do ponto escolhido.

Seja $I \subset (0, 1)$, então $\mathbb{P}(X \in I)$ será diretamente proporcional ao comprimento de I .

Qual é a fdp de X ? Podemos encontrar uma função f tal que:

$$\mathbb{P}(a < X < b) = \int_a^b f(x) dx$$

Perceba que se $a < b < 0$ ou $1 < a < b$, $\mathbb{P}(a < X < b) = 0$ e, portanto, $f(x) = 0$. Se $0 < a < b < 1$, $\mathbb{P}(a < X < b) = b - a$ e, portanto, $f(x) = 1$. Dessa forma, temos que:

$$f(x) = \begin{cases} 1, & 0 < x < 1 \\ 0, & \text{caso contrário} \end{cases}$$

Variáveis aleatórias contínuas

Exemplo 66: Suponha que X seja uma variável aleatória contínua cuja função densidade de probabilidade é dada por:

$$f_X(x) = \begin{cases} C(4x - 2x^2) & 0 < x < 2 \\ 0 & \text{caso contrário} \end{cases}$$

- a) Qual é o valor de C ?
- b) Determine $\mathbb{P}(X > 1)$

Variáveis aleatórias contínuas

A quantidade de tempo, em horas, que um computador funciona sem estragar é uma variável aleatória contínua com função de densidade de probabilidade:

$$f(x) = \begin{cases} \lambda e^{-x/100} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

Qual a probabilidade de que:

- a) O computador funcione entre 50 e 150 horas antes de estragar?
- b) Ele funcione pelo menos 100 horas?

Função distribuição de uma variável aleatória contínua

Vimos que sendo X uma variável aleatória discreta:

$$F_X(x) = \mathbb{P}(X \leq x)$$

Essa definição se manterá a mesma para variáveis aleatórias contínuas, no entanto, para obter a função distribuição teremos que nos valer do uso da integral.

Definição 10: Seja Y uma variável aleatória contínua, temos que sua função distribuição acumulada é dada por:

$$F_Y(y) = \mathbb{P}(Y \leq y) = \int_{-\infty}^y f_Y(y)$$

Esperança de Variáveis aleatórias contínuas

Para variáveis aleatórias discretas, vimos que a esperança de uma variável aleatória discreta X é dada por:

$$\mathbb{E}[X] = \sum_{x \in \Omega_X} x \mathbb{P}(X = x)$$

De forma análoga, sendo X uma variável aleatória contínua, temos que:

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f_X(x)$$

Variância de Variáveis aleatórias contínuas

A seguinte relação ainda é válida para variáveis aleatórias contínuas:

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

onde:

$$\mathbb{E}[X^2] = \int_{-\infty}^{\infty} x^2 f_X(x) dx$$

Distribuição Normal padrão

Uma variável aleatória Z tem distribuição **Normal padrão**, se:

- Z assume valores em $\mathbb{R}$
- A f.d.p f_Z é dada por:

$$f_Z(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}, z \in \mathbb{R}$$

Notação $Z \sim N(0, 1)$


Distribuição Normal padrão

Se $Z \sim N(0, 1)$, f_Z é simétrica em torno de 0

$$f_Z(z) = f_Z(-z) \forall z \in \mathbb{R}$$

Como a Normal padrão é uma distribuição contínua, a seguinte relação é válida:

$$\mathbb{P}(Z \leq z_0) = \int_{-\infty}^{z_0} \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \text{ para } z \in \mathbb{R}$$



Essa integral é impossível de ser resolvida analiticamente, nesse

Utilizando a tabela da Distribuição Normal padrão

Conforme visto no slide anterior, temos que utilizar tabelas.

Algumas informações importantes:

- A Normal não é a única distribuição na qual é preciso utilizar tabelas.
- Não existe apenas uma tabela da distribuição Normal, assim como veremos nessa aula.

Distribuição Normal padrão

Seja $Z \sim N(0, 1)$, calcule as seguintes probabilidades:

- $\mathbb{P}(Z > 0)$
- $\mathbb{P}(Z < 0)$
- $\mathbb{P}(Z \leq 0,76)$
- $\mathbb{P}(Z \geq 0,76)$
- $\mathbb{P}(Z \leq 1,79)$
- $\mathbb{P}(Z \geq 2,54)$
- $\mathbb{P}(Z > -0,5)$
- $\mathbb{P}(Z < -0,5)$
- $\mathbb{P}(Z < -1,43)$

Distribuição Normal(μ, σ)

Uma variável aleatória tem distribuição Normal com parâmetros μ, σ^2 , se:

- X assume valores em $\mathbb{R}$
- A f.d.p f_X é dada por:

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, x \in \mathbb{R}$$

Notação: $X \sim N(\mu, \sigma^2)$

Distribuição Normal(μ, σ)

Problema:

- Novamente temos uma função a qual não é possível calcular a integral analiticamente.
- Só temos uma tabela para calcular propriedades envolvendo a distribuição Normal e ela considera apenas distribuições normais com média 0 e variância 1, o que fazer?

Distribuição Normal(μ, σ)

Problema:

- Novamente temos uma função a qual não é possível calcular a integral analiticamente.
- Só temos uma tabela para calcular propriedades envolvendo a distribuição Normal e ela considera apenas distribuições normais com média 0 e variância 1, o que fazer?

Solução: Se $X \sim N(\mu, \sigma^2)$ então:


$$\frac{X - \mu}{\sigma} \sim N(0, 1)$$

Distribuição Normal(μ, σ)

Considere $X \sim N(10, 5)$ **Exemplos:**

- a) $\mathbb{P}(X \leq 13)$
- b) $\mathbb{P}(X \geq 11, 7)$
- c) $\mathbb{P}(X > 9.75)$
- d) $\mathbb{P}(X < 7.3)$
- e) $\mathbb{P}(9, 75 < X < 11, 7)$
- f) $\mathbb{P}(X < 9, 75 | X < 11, 7)$
- g) O valor de c tal que $\mathbb{P}(X > c) = 0.95$

Distribuição Normal(μ, σ)



Relembrando a Amostragem Aleatória Simples

Exercício: Explique como funciona a Amostragem Aleatória Simples.

Exemplo no R

Exemplo no R: Trabalho da Eduarda e da Larissa

Distribuições amostrais

No exemplo do trabalho da Larissa e Eduarda, vimos que:

- A média amostral parece convergir para a média populacional a medida que n aumentam

Distribuições amostrais

No exemplo do trabalho da Larissa e Eduarda, vimos que:

- A média amostral parece convergir para a média populacional a medida que n aumentam
- A variância das médias parece convergir para 0 a medida que n aumenta.

Distribuições amostrais

No exemplo do trabalho da Larissa e Eduarda, vimos que:

- A média amostral parece convergir para a média populacional a medida que n aumentam
- A variância das médias parece convergir para 0 a medida que n aumenta.
- A média das médias parece ser igual a verdadeira média a medida que o número de amostras aumenta.

Distribuições amostrais

No exemplo do trabalho da Larissa e Eduarda, vimos que:

- A média amostral parece convergir para a média populacional a medida que n aumentam
- A variância das médias parece convergir para 0 a medida que n aumenta.
- A média das médias parece ser igual a verdadeira média a medida que o número de amostras aumenta.
- A distribuição das médias parece ser Normal.

Distribuições amostrais

No exemplo do trabalho da Larissa e Eduarda, vimos que:

- A média amostral parece convergir para a média populacional a medida que n aumentam
- A variância das médias parece convergir para 0 a medida que n aumenta.
- A média das médias parece ser igual a verdadeira média a medida que o número de amostras aumenta.
- A distribuição das médias parece ser Normal.

Isso é sempre verdade?

Distribuições amostrais

No exemplo do trabalho da Larissa e Eduarda, vimos que:

- A média amostral parece convergir para a média populacional a medida que n aumentam
- A variância das médias parece convergir para 0 a medida que n aumenta.
- A média das médias parece ser igual a verdadeira média a medida que o número de amostras aumenta.
- A distribuição das médias parece ser Normal.

Isso é sempre verdade? De fato é verdade e o que nos garante isso são os dois resultados mais importantes da teoria das probabilidades, a Lei dos Grandes Números e o Teorema Central do Limite

Lei dos Grandes Números

A Lei dos Grandes Números possui duas versões (Na verdade mais de duas):

Lei dos Grandes Números

A Lei dos Grandes Números possui duas versões (Na verdade mais de duas):

Lei Fraca dos Grandes Números:

Seja $X_1, X_2, \dots, X_n$ uma sequência de variáveis aleatórias independentes e identicamente distribuídas (i.i.d.) com esperança $\mu = \mathbb{E}[X_i]$ e variância finita $\sigma^2 = \text{Var}(X_i) < \infty$. Então, para todo $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(\left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| > \varepsilon \right) = 0.$$

Lei dos Grandes Números

A Lei dos Grandes Números possui duas versões (Na verdade mais de duas):

Lei Fraca dos Grandes Números:

Seja $X_1, X_2, \dots, X_n$ uma sequência de variáveis aleatórias independentes e identicamente distribuídas (i.i.d.) com esperança $\mu = \mathbb{E}[X_i]$ e variância finita $\sigma^2 = \text{Var}(X_i) < \infty$. Então, para todo $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} \mathbb{P} \left(\left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| > \varepsilon \right) = 0.$$

Lei Forte dos Grandes Números:

Seja $X_1, X_2, \dots, X_n$ uma sequência de variáveis aleatórias independentes e identicamente distribuídas (i.i.d.) com esperança $\mu = \mathbb{E}[X_i]$. Suponha que $\mathbb{E}[|X_i|] < \infty$. Então,

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\text{quase certamente}} \mu, \text{ isto é, } \mathbb{P} \left(\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n X_i = \mu \right) = 1.$$

Teorema Central do Limite

Se n for suficientemente grande, então $\bar{X}$ terá uma distribuição aproximadamente Normal de média μ e variância σ^2/n , ou seja:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Primeira garantia: A média das médias amostrais é igual a verdadeira média

Por meio do Teorema Central do Limite, temos o seguinte resultado:

$$\mathbb{E}[\bar{X}] = \mu$$

Segunda garantia: A variância da média amostral

Além disso, temos também garantias sobre a variância:

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$$

Segunda garantia: A variância da média amostral

Além disso, temos também garantias sobre a variância:

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$$

Perceba que quando $n \rightarrow \infty$, $\frac{\sigma^2}{n} \rightarrow 0$

Teorema Central do Limite

Outra forma de ver o **Teorema Central do Limite** é o padronizando:

Seja $X_1, X_2, \dots, X_n$ uma sequência de variáveis aleatórias independentes e identicamente distribuídas com média μ e variância σ^2 , então:

$$\frac{\bar{X} - \mathbb{E}[\bar{X}]}{\sqrt{\text{Var}(\bar{X})}} = \frac{\bar{X} - \mu}{\sqrt{\frac{\sigma^2}{n}}} \xrightarrow[n \rightarrow \infty]{\text{em distribuição}} N(0, 1)$$

$$\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n\sigma^2}} \xrightarrow[n \rightarrow \infty]{\text{em distribuição}} N(0, 1)$$

Teorema Central do Limite

Outra forma de ver o **Teorema Central do Limite** é o padronizando:

Seja $X_1, X_2, \dots, X_n$ uma sequência de variáveis aleatórias independentes e identicamente distribuídas com média μ e variância σ^2 , então:

$$\frac{\bar{X} - \mathbb{E}[\bar{X}]}{\sqrt{\text{Var}(\bar{X})}} = \frac{\bar{X} - \mu}{\sqrt{\frac{\sigma^2}{n}}} \xrightarrow[n \rightarrow \infty]{\text{em distribuição}} N(0, 1)$$


$$\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n\sigma^2}} \xrightarrow[n \rightarrow \infty]{\text{em distribuição}} N(0, 1)$$

Uma pergunta que fica é: Na prática, qual n é considerado suficientemente grande?

Estimação por intervalo

- Até agora só vimos os estimadores pontuais, que fornecem como estimativa um único valor numérico para o parâmetro de interesse.
- O método de estimação por intervalo visa estabelecer um intervalo de confiança, incorpora, à estimativa pontual do parâmetro, informações a respeito da variabilidade do estimador. Intervalos de confiança são obtidos através da distribuição amostral de seus estimadores.

Intervalo de confiança



Caso 1: Variância conhecida

Considere que temos interesse em construir um intervalo de confiança para a média μ de uma certa população com variância conhecida σ^2 . Supondo uma amostra de tamanho n , vimos que a média amostral tem distribuição Normal com a mesma média μ e variância σ^2/n , ou seja,

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Caso 1: Variância conhecida

Considere que temos interesse em construir um intervalo de confiança para a média μ de uma certa população com variância conhecida σ^2 . Supondo uma amostra de tamanho n , vimos que a média amostral tem distribuição Normal com a mesma média μ e variância σ^2/n , ou seja,

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

Logo, fixando um valor α tal que $0 < \alpha < 1$, podemos encontrar dois valores a e b tal que:

$$\mathbb{P}(a < Z < b) = \alpha$$

Caso 1: Variância conhecida

$$\mathbb{P}(a < Z < b) = \alpha$$

- Perceba que, como a distribuição Normal é simétrica, podemos dizer que $a = -b$.
- Além disso, a e b são funções de α . Qual é a regra dessa função?

Caso 1: Variância conhecida


$$\mathbb{P}(a < Z < b) = \alpha$$

- Perceba que, como a distribuição Normal é simétrica, podemos dizer que $a = -b$.
- Além disso, a e b são funções de α . Qual é a regra dessa função?

De fato, $a = -z_{\alpha/2}$ e $b = z_{\alpha/2}$

Caso 1: Variância conhecida

$$\mathbb{P}(-z_{\alpha/2} < Z < z_{\alpha/2}) = \alpha$$



Caso 1: Variância conhecida

Substituindo, temos que:

$$\begin{aligned} \mathbb{P}(-z_{\alpha/2} < Z < z_{\alpha/2}) &= \mathbb{P}\left(-z_{\alpha/2} < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < z_{\alpha/2}\right) \\ &= \mathbb{P}\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) \end{aligned}$$

Dessa forma, o intervalo de confiança para μ , com coeficiente de confiança α é dado por:

$$IC(\mu, \alpha) = \left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}; \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

$z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ é denominada margem de erro.

Caso 1: Variância conhecida

Super Mega Importante - Interpretação do intervalo de confiança: Se obtivermos várias amostras de mesmo tamanho e, para cada uma delas, calcularmos os correspondentes intervalos de confiança com coeficiente de confiança α , esperamos que a proporção de intervalos que contenham o valor de μ seja igual a α . Ou seja, se coletarmos 1000 amostras encontrarmos o intervalo de confiança para μ com nível de confiança 95%, então espera-se que 950 intervalos contenham a média populacional.

Caso 1: Variância conhecida

Super Mega Importante - Interpretação do intervalo de confiança: Se obtivermos várias amostras de mesmo tamanho e, para cada uma delas, calcularmos os correspondentes intervalos de confiança com coeficiente de confiança α , esperamos que a proporção de intervalos que contenham o valor de μ seja igual a α . Ou seja, se coletarmos 1000 amostras encontrarmos o intervalo de confiança para μ com nível de confiança 95%, então espera-se que 950 intervalos contenham a média populacional.



Caso 1: Variância conhecida

Exemplo 67: Considere que a altura dos estudantes de uma escola siga a distribuição Normal com média μ desconhecida e variância igual a 10^{-2} . Uma amostra de dez estudantes foi sorteada e forneceu média 1,69. Forneça uma estimativa para o parâmetro desconhecido μ

Caso 1: Variância conhecida

Exemplo 68: Considere que a altura dos estudantes de uma escola siga a distribuição Normal com média μ desconhecida e variância igual a 10^{-2} . Uma amostra de dez estudantes foi sorteada e forneceu média 1,69. Forneça uma estimativa para o parâmetro desconhecido μ com 95% de confiança e interprete o resultado obtido.

Caso 1: Variância conhecida

Exemplo 69: Considere que a altura dos estudantes de uma escola siga a distribuição Normal com média μ desconhecida e variância igual a 10^{-2} . Uma amostra de dez estudantes foi sorteada e forneceu média 1,69. Forneça uma estimativa para o parâmetro desconhecido μ com 95% de confiança e interprete o resultado obtido. Agora calcule com 99% de confiança.

Caso 1: Variância conhecida

Exemplo 70: Considere que a altura dos estudantes de uma escola siga a distribuição Normal com média μ desconhecida e variância igual a 10^{-2} . Uma amostra de dez estudantes foi sorteada e forneceu média 1,69. Forneça uma estimativa para o parâmetro desconhecido μ com 95% de confiança e interprete o resultado obtido. Agora calcule com 99% de confiança. Agora calcule com 50% de confiança.

Caso 3: Proporção

Um estimador (estatística) natural para estimar a proporção populacional seria considerar seria basicamente somar a quantidade dos eventos de interesse e dividir pelo total:

$$\hat{p} = \frac{\sum_{i=1}^n W_i}{n}$$

Logo,

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$$

Caso 3: Proporção

Dessa forma, um intervalo de confiança com nível de confiança α é dado da seguinte forma:

$$IC(\pi, \alpha) = \left[\hat{p} - z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}}; \hat{p} + z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}} \right]$$

Caso 3: Proporção

Exemplo 71: Uma empresa visa oferecer uma conta universitária para os alunos da UFRJ e gostaria de saber quantos alunos vão aceitar a oferta. A empresa decide enviar uma oferta para 1000 alunos e 140 aceitam criar a conta universitária

- 1) Qual o tamanho da amostra (n)?
- 2) Qual a proporção amostral ($\hat{p}$)
- 3) Construa um intervalo de confiança com 5% de significância para a proporção de alunos que irão aceitar criar a conta.

Caso 3: Proporção

Exemplo 72: Numa pesquisa com 50 eleitores, o candidato José João obteve a preferência de 17 desses eleitores. Supondo que a eleição ocorresse na época da pesquisa, construa os intervalos de confiança otimista e conservador ($p=1/2$) para a proporção de votos a serem recebidos pelo candidato mencionado. Use um coeficiente de confiança igual a 94%.

Calculando o tamanho da amostra

Exemplo 73: Uma pesquisa eleitoral tem o objetivo de entender quantas pessoas irão votar em um determinado prefeito no ano de 2024. Ela deseja ter uma margem de erro de 1% para mais ou para menos e com nível de confiança 95%. Com base em experiências passadas, ela espera que aproximadamente 50% dos entrevistados irão votar no candidato.

Calculando o tamanho da amostra

Exemplo 74: Uma pesquisa eleitoral tem o objetivo de entender quantas pessoas irão votar em um determinado prefeito no ano de 2024. Ela deseja ter uma margem de erro de 1% para mais ou para menos e com nível de confiança 95%. Com base em experiências passadas, ela espera que aproximadamente 50% dos entrevistados irão votar no candidato.

Temos que:

$$\begin{aligned} z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}} &= 0,01 \implies 1,96 \cdot \sqrt{\frac{0,25}{n}} = 0,1 \\ \implies \frac{0,25}{n} &= \left(\frac{0,01}{1,96}\right)^2 \implies n \approx 9604 \end{aligned}$$